analisis-exploratorio-a01633819

September 9, 2023

0.1 Actividad: Análisis exploratorio con técnicas de agrupamiento Andrés Alejandro Guzmán González - A01633819

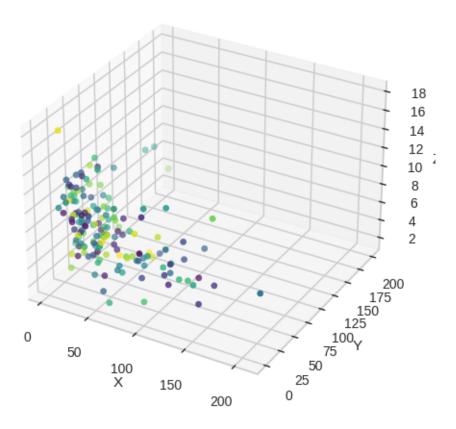
Descarga el conjunto de datos socioeconómicos de los países del mundo, y haz lo siguiente:

[161]:			country	child_mort	exports	health	imports	income	\
	0	Af	ghanistan	90.2	10.0	7.58	44.9	1610	
	1	Albania		16.6	28.0	6.55	48.6	9930	
	2	Algeria		27.3	38.4	4.17	31.4	12900	
	3		Angola	119.0	62.3	2.85	42.9	5900	
	4	Antigua and Barbuda		10.3	45.5	6.03	58.9	19100	
		inflation	life_expec	total_fer	gdpp				
	0	9.44	56.2	5.82	553				
	1	4.49	76.3	1.65	4090				
	2	16.10	76.5	2.89	4460				
	3	22.40	60.1	6.16	3530				
	4	1.44	76.8	3 2.13	12200				

```
[162]: df
[162]:
                                   child_mort
                                                exports health
                                                                   imports
                                                                            income \
                          country
       0
                     Afghanistan
                                          90.2
                                                    10.0
                                                            7.58
                                                                      44.9
                                                                               1610
       1
                          Albania
                                          16.6
                                                    28.0
                                                            6.55
                                                                      48.6
                                                                               9930
       2
                          Algeria
                                                            4.17
                                                                      31.4
                                          27.3
                                                    38.4
                                                                              12900
       3
                           Angola
                                         119.0
                                                    62.3
                                                            2.85
                                                                      42.9
                                                                               5900
       4
             Antigua and Barbuda
                                          10.3
                                                    45.5
                                                            6.03
                                                                      58.9
                                                                              19100
       162
                          Vanuatu
                                          29.2
                                                    46.6
                                                            5.25
                                                                      52.7
                                                                               2950
       163
                       Venezuela
                                          17.1
                                                    28.5
                                                            4.91
                                                                      17.6
                                                                              16500
       164
                          Vietnam
                                          23.3
                                                    72.0
                                                            6.84
                                                                      80.2
                                                                               4490
       165
                            Yemen
                                          56.3
                                                    30.0
                                                            5.18
                                                                      34.4
                                                                               4480
       166
                                                            5.89
                                                                      30.9
                           Zambia
                                          83.1
                                                    37.0
                                                                               3280
             inflation life_expec total_fer
                                                  gdpp
       0
                  9.44
                               56.2
                                           5.82
                                                    553
                  4.49
       1
                               76.3
                                           1.65
                                                   4090
       2
                 16.10
                               76.5
                                           2.89
                                                   4460
       3
                 22.40
                               60.1
                                           6.16
                                                   3530
       4
                  1.44
                               76.8
                                           2.13
                                                 12200
       . .
                   •••
                                             •••
       162
                  2.62
                               63.0
                                           3.50
                                                  2970
       163
                 45.90
                               75.4
                                                 13500
                                           2.47
       164
                 12.10
                               73.1
                                           1.95
                                                   1310
       165
                 23.60
                               67.5
                                           4.67
                                                   1310
       166
                 14.00
                               52.0
                                           5.40
                                                   1460
       [167 rows x 10 columns]
[163]: df.isnull().sum()
[163]: country
                      0
       child_mort
                      0
       exports
                      0
       health
                      0
       imports
                      0
       income
       inflation
                      0
       life_expec
                      0
       total_fer
                      0
                      0
       gdpp
       dtype: int64
[164]: label_encoder = LabelEncoder()
       df['country'] = label_encoder.fit_transform(df['country'])
       df.head()
```

```
[164]:
         country
                  child_mort exports health
                                                imports
                                                        income
                                                                 inflation \
                                  10.0
                                                   44.9
                                                                      9.44
      0
                0
                         90.2
                                          7.58
                                                           1610
                                                                      4.49
       1
                1
                         16.6
                                  28.0
                                          6.55
                                                   48.6
                                                           9930
       2
                2
                         27.3
                                  38.4
                                          4.17
                                                   31.4
                                                          12900
                                                                      16.10
                3
                                                                     22.40
       3
                        119.0
                                  62.3
                                          2.85
                                                   42.9
                                                           5900
       4
                4
                         10.3
                                  45.5
                                          6.03
                                                   58.9
                                                          19100
                                                                      1.44
         life_expec total_fer
                                  gdpp
       0
                56.2
                           5.82
                                  553
                76.3
                           1.65
       1
                                  4090
       2
                76.5
                           2.89
                                  4460
       3
                60.1
                           6.16
                                  3530
       4
                76.8
                           2.13 12200
[165]: df.columns
[165]: Index(['country', 'child_mort', 'exports', 'health', 'imports', 'income',
              'inflation', 'life_expec', 'total_fer', 'gdpp'],
             dtype='object')
[166]: def plot_data(points, labels, title):
           fig = plt.figure()
           if points.shape[1] > 2:
               ax = fig.add_subplot(projection='3d')
               ax.scatter(points[:,0], points[:,1], points[:,2], c=labels,_
        ax.set xlabel('X')
               ax.set_ylabel('Y')
               ax.set zlabel('Z')
               ax.set_title(title)
           else:
               plt.scatter(points[:,0], points[:,1], c=labels, cmap='viridis')
               plt.xlabel('X')
               plt.ylabel('Y')
               plt.title(title)
           plt.show()
[167]: x = df.drop('country', axis=1).values
       y = df['country'].values
       plot_data(x,y,"Data - Contries")
```

Data - Contries



1. Aplica k-medias sobre le conjunto de datos para generar un agrupamiento para los países de la base de datos. Utiliza al menos dos métodos para estimar el número óptimo de grupos.

```
[168]: print('---- K-means -----')

kmeans = KMeans(n_clusters=8, n_init=8, random_state=0)
kmeans.fit(x)
clustering_labels = kmeans.labels_
centers = kmeans.cluster_centers_

print('Labels: ', clustering_labels)
print('Centers: ', centers)

plot_data(x, clustering_labels, 'K-Means')

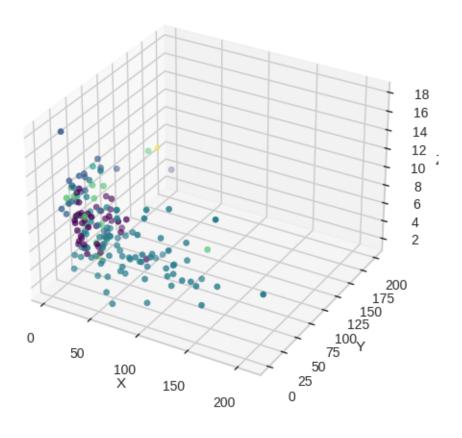
# Optimal number of clusters
sum_of_squared_distances = []
sscore = []
chscore = []
```

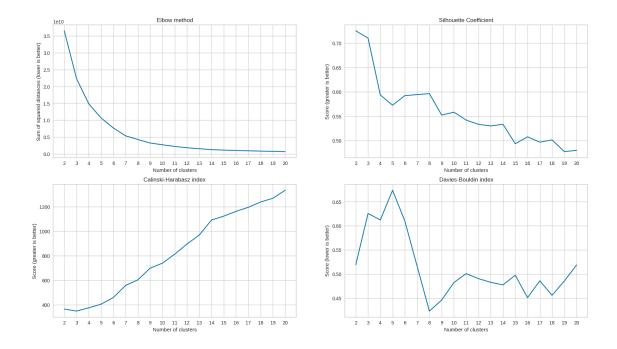
```
dbscore = []
ks = np.arange(2, 21)
for k in ks:
    # Find clustering model
    kmeans = KMeans(n_clusters=k, n_init=k)
    kmeans.fit(x)
    # Evaluate sum of squared distances
    sum_of_squared_distances.append(kmeans.inertia_)
    # Evaluate Silhouette score
    sscore.append(silhouette score(x, kmeans.labels ))
    # Evaluate Calinski-Harabasz index
    chscore.append(calinski_harabasz_score(x, kmeans.labels_))
    # Evaluate Davies-Bouldin index
    dbscore.append(davies_bouldin_score(x, kmeans.labels_))
print("\n")
fig, axs = plt.subplots(2, 2, figsize=(20,11))
axs[0][0].plot(ks, sum of squared distances)
axs[0][0].set_xlabel('Number of clusters')
axs[0][0].set ylabel('Sum of squared distances (lower is better)')
axs[0][0].set_title('Elbow method')
axs[0][0].set_xticks(ks)
axs[0][1].plot(ks, sscore)
axs[0][1].set_xlabel('Number of clusters')
axs[0][1].set_ylabel('Score (greater is better)')
axs[0][1].set_title('Silhouette Coefficient')
axs[0][1].set_xticks(ks)
axs[1][0].plot(ks, chscore)
axs[1][0].set xlabel('Number of clusters')
axs[1][0].set_ylabel('Score (greater is better)')
axs[1][0].set title('Calinski-Harabasz index')
axs[1][0].set_xticks(ks)
axs[1][1].plot(ks, dbscore)
axs[1][1].set_xlabel('Number of clusters')
axs[1][1].set_ylabel('Score (lower is better)')
axs[1][1].set_title('Davies-Bouldin index')
axs[1][1].set_xticks(ks)
```

plt.show()

```
---- K-means -----
Labels: [3 3 0 3 0 0 3 2 2 0 5 5 3 0 0 2 3 3 3 3 3 0 0 1 0 3 3 3 3 2 3 3 3 0 3
0 3
3\ 3\ 0\ 3\ 0\ 5\ 5\ 2\ 0\ 3\ 3\ 5\ 3\ 0\ 3\ 2\ 2\ 0\ 3\ 3\ 2\ 3\ 5\ 0\ 3\ 3\ 3\ 3\ 3\ 0\ 2\ 3\ 3\ 0\ 0\ 2
5\ 2\ 3\ 2\ 3\ 0\ 3\ 3\ 1\ 3\ 3\ 0\ 0\ 3\ 3\ 5\ 0\ 7\ 0\ 3\ 3\ 0\ 0\ 3\ 5\ 3\ 0\ 3\ 3\ 3\ 3\ 3\ 3\ 3\ 2
 5\ 3\ 3\ 4\ 5\ 3\ 0\ 3\ 3\ 3\ 0\ 5\ 6\ 0\ 0\ 3\ 3\ 5\ 3\ 0\ 0\ 3\ 1\ 5\ 5\ 3\ 0\ 5\ 5\ 3\ 0\ 3\ 0\ 2\ 4\ 3\ 3
 0 3 3 3 3 0 3 3 3 1 2 2 0 3 3 0 3 3 3
Centers: [[1.77357143e+01 4.38476190e+01 6.69952381e+00 4.52071429e+01
  1.61576190e+04 7.26590476e+00 7.33880952e+01 2.06785714e+00
  8.94761905e+03]
 [8.17500000e+00 1.02950000e+02 3.27250000e+00 7.40000000e+01
 7.13750000e+04 1.00885000e+01 7.86250000e+01 1.76750000e+00
  3.88500000e+041
 [4.29375000e+00 4.31437500e+01 1.07662500e+01 4.01312500e+01
 4.11250000e+04 1.09125000e+00 8.08062500e+01 1.79625000e+00
 4.61125000e+04]
 [6.30642857e+01 3.10392738e+01 6.14821429e+00 4.59448321e+01
 4.32670238e+03 9.84197619e+00 6.49273810e+01 3.89309524e+00
  1.94778571e+03]
 [3.85000000e+00 5.18500000e+01 1.04900000e+01 4.09000000e+01
  5.89000000e+04 3.13350000e+00 8.16000000e+01 1.73500000e+00
  8.12000000e+041
 [1.34058824e+01 5.72470588e+01 7.32235294e+00 5.21705882e+01
  3.19470588e+04 5.47005882e+00 7.73647059e+01 2.08588235e+00
  2.32176471e+04]
 [9.0000000e+00 6.23000000e+01 1.81000000e+00 2.38000000e+01
  1.25000000e+05 6.98000000e+00 7.95000000e+01 2.07000000e+00
 7.03000000e+041
 [2.80000000e+00 1.75000000e+02 7.77000000e+00 1.42000000e+02
  9.1700000e+04 3.62000000e+00 8.13000000e+01 1.63000000e+00
  1.05000000e+05]]
```

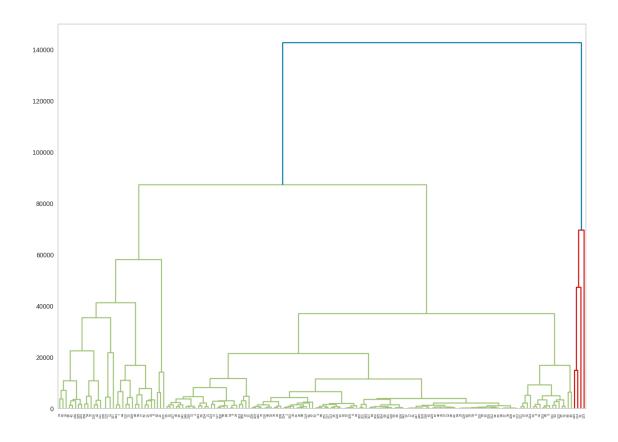
K-Means



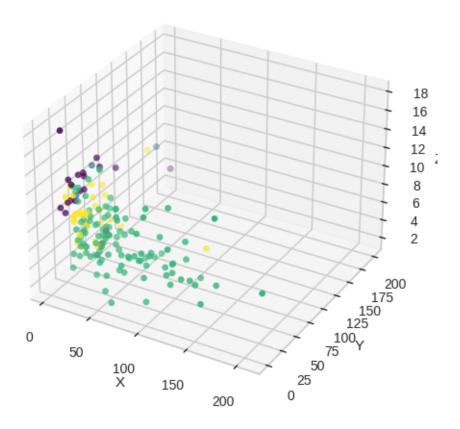


2. Repita lo anterior, pero con otro método de agrupamiento que elijas.

---- Dendrogram plot ----



Aglomerative clustering



3. Investiga qué librerías hay en Python para la implementación de mapas autoorganizados, y selecciona alguna para el agrupamiento de los datos de este ejercicio. Algunos ejemplos de librerías son: MinosomLinks to an external site. sklearn-somLinks to an external site.

[171]: | pip install sklearn-som

Requirement already satisfied: sklearn-som in /usr/local/lib/python3.10/dist-packages (1.1.0)

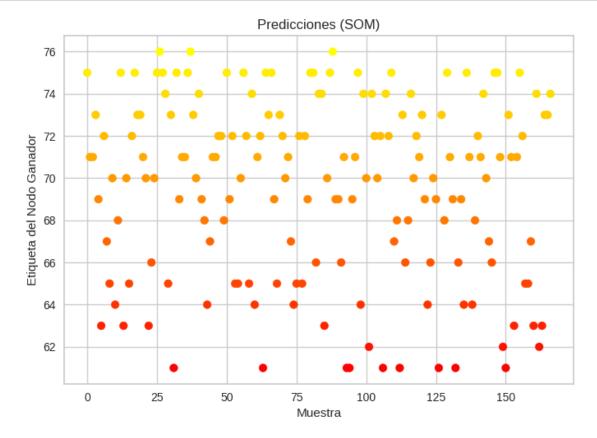
Requirement already satisfied: numpy in /usr/local/lib/python3.10/dist-packages (from sklearn-som) (1.23.5)

```
[172]: from sklearn_som.som import SOM
   _som = SOM(m=167, n=1, dim=9)
   _som.fit(x)
   predictions = _som.predict(x)
   predictions
```

[172]: array([75, 71, 71, 73, 69, 63, 72, 67, 65, 70, 64, 68, 75, 63, 70, 65, 72, 75, 73, 73, 71, 70, 63, 66, 70, 75, 76, 75, 74, 65, 73, 61, 75, 69,

```
71, 71, 75, 76, 73, 70, 74, 69, 68, 64, 67, 71, 71, 72, 72, 68, 75, 69, 72, 65, 65, 70, 75, 72, 65, 74, 64, 71, 72, 61, 75, 73, 75, 69, 65, 73, 72, 70, 71, 67, 64, 65, 72, 65, 72, 69, 75, 75, 66, 74, 74, 63, 70, 75, 76, 69, 69, 66, 71, 61, 61, 69, 71, 75, 64, 74, 70, 62, 74, 72, 70, 72, 61, 74, 72, 75, 67, 68, 61, 73, 66, 68, 74, 70, 72, 71, 73, 69, 64, 66, 70, 69, 61, 73, 68, 75, 71, 69, 61, 66, 69, 64, 75, 71, 64, 68, 72, 71, 74, 70, 67, 66, 75, 75, 71, 62, 61, 73, 71, 63, 71, 75, 72, 65, 65, 67, 63, 74, 62, 63, 73, 73, 74])
```

```
[173]: plt.scatter(range(len(predictions)), predictions, c=predictions, cmap='autumn')
   plt.title('Predicciones (SOM)')
   plt.xlabel('Muestra')
   plt.ylabel('Etiqueta del Nodo Ganador')
   plt.grid(True)
   plt.show()
```



4. De los resultados que se obtienen del agrupamiento, indica si los grupos formados siguen algun patrón que esperabas, o tiene información nueva que no hayas considerado anteriormente.

Comenzando con K-Means, puede observar que que algunos de los etiquetados solo alcanzan valores máximos de 8 y estos no constituyen la mayoría de las etiquetas. Teniendo en cuenta que inicialmente usé un total de 10 clústeres, podría argumentar que reduciendo el número de clústeres a un

valor óptimo, como 8, se puede mejorar el proceso de clasificación eliminando los casos aislados en que la etiqueta fue igual a 8 y, en su lugar, asignarles una etiqueta más apropiada.

En cualquier caso, el método "Elbow" resultó ser muy adecuado para el conjunto de datos. El coeficiente de Silhouette fue menos satisfactorio, mientras que el índice Calinski-Harabasz mostró un buen rendimiento. Además, el índice Davies-Bouldin respaldó la idea mencionada anteriormente. Estos métodos se basan en la cantidad de clústeres, lo que nos proporciona valiosos parámetros para interpretar K-Means y la clasificación de los datos. Finalmente, el Mapa Autoorganizado (SOM), resultó ser muy útil para detectar nodos ganadores en la muestra de datos, es decir, la variable predictora.