problemasderegresion-a01633819

September 1, 2023

1 Actividad: Problemas de regresión

Andrés Alejandro Guzmán González - A01633819

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn import datasets
from sklearn import linear_model
from sklearn.preprocessing import StandardScaler
from sklearn.model_selection import KFold, LeaveOneOut, ShuffleSplit
from sklearn.metrics import mean_squared_error, mean_absolute_error, r2_score
from sklearn.linear_model import Lasso, LassoCV
from sklearn.model_selection import train_test_split
```

1.1 Ejercicio 1

El conjunto de **datos de criminalidad de Estados Unidos** publicado en el año 1993 consiste de 51 registros para los que se tienen las siguientes variables:

- VR = crímenes violentos por cada 100000 habitantes
- MR = assinatos por cada 100000 habitantes
- M = porcentaje de áreas metropolitanas
- W = porcentaje de gente blanca
- H = porcentaje de personas con preparatoria terminada
- \bullet P = porcentaje con ingresos por debajo del nivel de pobreza
- ullet S = porcentaje de familias con solo un miembro adulto como tutor

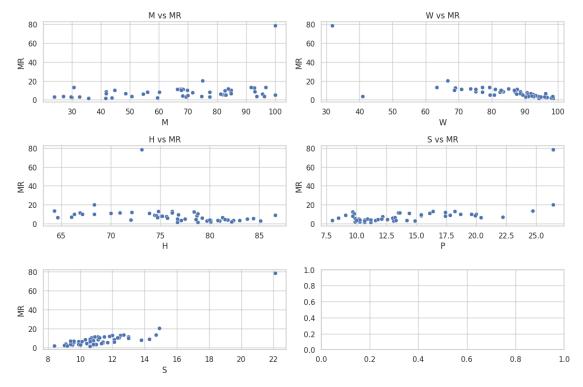
Consideraciones: * Terminación de matrícula: 9 * Variable dependiente MR, variables independientes M, W, H, P y S. * El método de validación cruzada a utilizar en el punto 4: **LOOCV**

```
[2]: df = pd.read_csv('/content/sample_data/crime_data.csv')
    df.head()
```

```
[2]:
       State
                                                   Ρ
                 VR.
                       MR.
                               М
                                      W
                                            Η
                                  75.2
                                                9.1
     0
                761
                      9.0
                            41.8
                                         86.6
           AK
     1
                780
                     11.6
                            67.4 73.5
                                         66.9
                                               17.4
           ΑL
```

```
2
         AR
              593 10.2 44.7 82.9 66.3 20.0 10.7
    3
                    8.6 84.7
                               88.6
                                     78.7 15.4 12.1
         ΑZ
              715
         CA 1078
                  13.1 96.7 79.3 76.2 18.2 12.5
[3]: df.isnull().sum()
[3]: State
    VR.
             0
    MR.
             0
    М
             0
    W
             0
    Η
             0
    Р
             0
    S
             0
    dtype: int64
[4]: df = df.drop(columns=['State', 'VR'])
    df.head()
[4]:
         MR.
                            Η
                                  Р
                                        S
                Μ
                      W
        9.0 41.8
                   75.2
                         86.6
                                9.1
                                     14.3
    1 11.6 67.4 73.5
                         66.9
                               17.4
                                     11.5
    2 10.2 44.7 82.9
                         66.3
                               20.0 10.7
       8.6 84.7 88.6
                         78.7
                               15.4 12.1
    4 13.1 96.7 79.3 76.2 18.2 12.5
[5]: correl = df.corr()
[6]: alta_corr=np.where((correl > 0.95)&(correl < 1))
    alta_corr
[6]: (array([], dtype=int64), array([], dtype=int64))
[7]: # Grafica cada variable predictora vs la variable de respuesta asignadas
     # a tu número de matrícula.
    sns.set(style="whitegrid")
    fig, axes = plt.subplots(nrows=3, ncols=2, figsize=(12, 8))
    plt.subplots_adjust(hspace=0.5)
    sns.scatterplot(data=df, x='M', y='MR', ax=axes[0, 0])
    axes[0, 0].set_title('M vs MR')
    sns.scatterplot(data=df, x='W', y='MR', ax=axes[0, 1])
    axes[0, 1].set_title('W vs MR')
    sns.scatterplot(data=df, x='H', y='MR', ax=axes[1, 0])
```

```
axes[1, 0].set_title('H vs MR')
sns.scatterplot(data=df, x='P', y='MR', ax=axes[1, 1])
axes[1, 1].set_title('P vs MR')
sns.scatterplot(data=df, x='S', y='MR', ax=axes[2, 0])
axes[1, 1].set_title('S vs MR')
plt.tight_layout()
plt.show()
```



Implementa la fórmula directa para calcular los coeficientes de un modelo de regresión lineal, y obtenga con ella el modelo que corresponde a la variable de respuesta y las variables predictoras asignadas a tu número de matrícula.

```
[8]: # Variables regresoras
x = np.array(df[['M','W','H','P','S']])
y = np.array(df['MR'])

# Promedio de los valores
x_mean = x.mean()
y_mean = y.mean()
```

```
[9]: def model_fit(x,y):
       return np.linalg.inv(x.T @ x) @ x.T @ y
     def prediction(x, b):
       return x @ b
[10]: x = np.column_stack((np.ones(x.shape[0]), x))
[11]: betas = model_fit(x,y)
     betas
[11]: array([-33.73141336,
                            0.05104714, -0.195887 ,
                                                      0.1995895 ,
              0.58140297,
                            2.82467971])
[12]: y_predict = prediction(x, betas)
     y_predict
[12]: array([16.6397921, 11.26423508, 7.39627738, 12.07661488, 16.76975615,
             9.1045627, 2.9985335, 8.53660241, 9.79944258, 14.57635013,
             8.41295779, -3.02054615, -0.78415304, 10.28931619, 4.86482275,
             3.05696635, 5.45765325, 28.10018798, 6.31119626, 12.69272897,
             0.68636906, 15.2148908, 2.54755361, 7.49466559, 24.15313644,
             4.69077614, 8.61972199, -4.51287051, -0.75371144, -1.74693984,
             4.30836316, 16.15163165, 10.06541115, 16.16486845, 8.14711888,
            10.98908261, 6.63119785, 2.9229871, 4.29616068, 15.64158746,
             0.45997764, 9.9294006, 11.71949299, 3.10752753, 4.86479237,
             1.38391644, 9.80252992, 4.09378506, 2.17048088, 3.80425199,
            57.50854645])
[13]: # Calculamos el coeficiente de correlación
     r = y - y_predict
[13]: array([-7.63979210e+00, 3.35764918e-01, 2.80372262e+00, -3.47661488e+00,
            -3.66975615e+00, -3.30456270e+00, 3.30146650e+00, -3.53660241e+00,
            -8.99442576e-01, -3.17635013e+00, -4.61295779e+00, 5.32054615e+00,
             3.68415304e+00, 1.11068381e+00, 2.63517725e+00, 3.34303365e+00,
             1.14234675e+00, -7.80018798e+00, -2.41119626e+00, 7.27102586e-03,
             9.13630937e-01, -5.41489080e+00, 8.52446386e-01, 3.80533441e+00,
            -1.06531364e+01, -1.69077614e+00, 2.68027801e+00, 6.21287051e+00,
             4.65371144e+00, 3.74693984e+00, 9.91636843e-01, -8.15163165e+00,
             3.34588849e-01, -2.86486845e+00, -2.14711888e+00, -2.58908261e+00,
            -2.03119785e+00, 3.87701290e+00, -3.96160682e-01, -5.34158746e+00,
             2.94002236e+00, 2.70599398e-01, 1.80507011e-01, -7.52752527e-03,
             3.43520763e+00, 2.21608356e+00, -4.60252992e+00, 3.06214936e-01,
             4.72951912e+00, -4.04251988e-01, 2.09914536e+01])
```

Evalúa con validación cruzada de k-pliegues tu modelo, calculando los valores de r^2 , MSE y MAE.

```
[14]: folds = 5
      kf = KFold(n_splits=folds, shuffle=True)
      mse = []
      mae = []
      r2 = []
      for train_index, test_index in kf.split(x):
        # Training phase
        x_train = x[train_index, : ]
        y_train = y[train_index]
        regression = linear_model.LinearRegression()
        regression.fit(x_train, y_train)
        # Test phase
        x_test = x[test_index, : ]
        y_test = y[test_index]
        y_predict = regression.predict(x_test)
        # Calculate MSE, MAE & R~2
        mse_i = mean_squared_error(y_test, y_predict)
        mse.append(mse_i)
        mae_i = mean_absolute_error(y_test, y_predict)
        mae.append(mae_i)
        r2_i = r2_score(y_test, y_predict)
        r2.append(r2_i)
      print('MSE:', np.average(mse), ' MAE:', np.average(mae),' R^2:', np.average(r2))
```

MSE: 65.57121836754496 MAE: 3.959793835761245 R^2: -1.4913181846777346

Utiliza el método de validación cruzada asignado a tu matrícula para mostrar los histogramas de R2 (sólo si es el método de Monte Carlo), MSE y MAE.

```
[15]: kf = LeaveOneOut()
    mse_cv = []
    mae_cv = []
    for train_index, test_index in kf.split(x):
        # Training phase
        x_train = x[train_index, :]
        y_train = y[train_index]

        regr_cv = linear_model.LinearRegression()
        regr_cv.fit(x_train, y_train)

        # Test phase
        x_test = x[test_index, :]
        y_test = y[test_index]

        y_pred = regr_cv.predict(x_test)
```

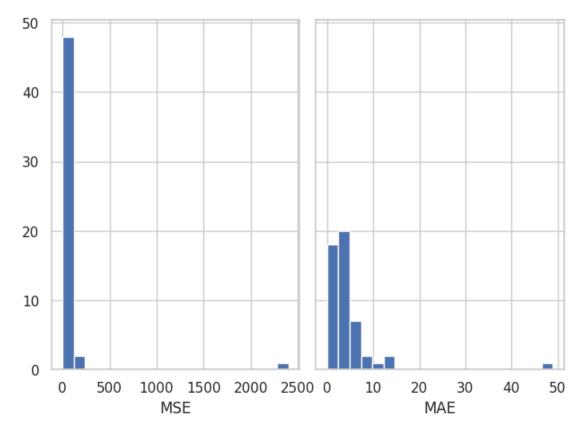
```
# Calculate MSE and MAE
mse_i = mean_squared_error(y_test, y_pred)
mse_cv.append(mse_i)

mae_i = mean_absolute_error(y_test, y_pred)
mae_cv.append(mae_i)

fig, axs = plt.subplots(1, 2, sharey=True, tight_layout=True)
axs[0].hist(mse_cv, bins=20)
axs[0].set_xlabel("MSE")

axs[1].hist(mae_cv, bins=20)
axs[1].set_xlabel("MAE")

plt.show()
```



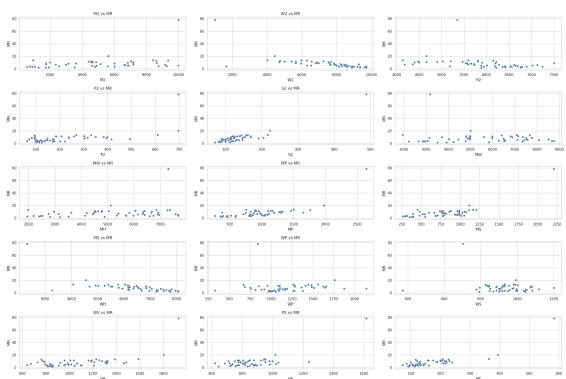
Agrega al conjunto de datos columnas que representen los cuadrados de las variables predictoras (por ejemplo, M2, W2), así como los productos entre pares de variables (por ejemplo, PxS, MxW). Repita los pasos 1, 2 y 3 pero con este nuevo conjunto de datos.

```
[16]: df2 = pd.DataFrame()
     df2['MR'] = df['MR']
     df2['M2'] = df['M']**2
     df2['W2'] = df['W']**2
     df2['H2'] = df['H']**2
     df2['P2'] = df['P']**2
     df2['S2'] = df['S']**2
     df2['MW'] = df['M'] * df['W']
     df2['MH'] = df['M'] * df['H']
     df2['MP'] = df['M'] * df['P']
     df2['MS'] = df['M'] * df['S']
     df2['WH'] = df['W'] * df['H']
     df2['WP'] = df['W'] * df['P']
     df2['WS'] = df['W'] * df['S']
     df2['HP'] = df['H'] * df['P']
     df2['HS'] = df['H'] * df['S']
     df2['PS'] = df['P'] * df['S']
     df2.head()
[16]:
                            W2
                                    Н2
                                            P2
                                                    S2
          MR.
                   M2
                                                            MW
                                                                     MH
                                                                              MP \
                                         82.81 204.49 3143.36
         9.0 1747.24 5655.04 7499.56
                                                                3619.88
                                                                          380.38
                       5402.25 4475.61 302.76 132.25 4953.90
     1 11.6 4542.76
                                                                4509.06 1172.76
     2 10.2 1998.09
                       6872.41 4395.69 400.00
                                                114.49
                                                       3705.63
                                                                2963.61
                                                                          894.00
     3 8.6 7174.09
                      7849.96 6193.69 237.16 146.41
                                                        7504.42
                                                                6665.89
                                                                         1304.38
     4 13.1 9350.89 6288.49 5806.44 331.24 156.25 7668.31
                                                                7368.54 1759.94
             MS
                                                ΗP
                                                                PS
                      WH
                              WP
                                       WS
                                                         HS
     0
         597.74 6512.32
                           684.32 1075.36
                                           788.06 1238.38 130.13
     1
         775.10 4917.15 1278.90
                                  845.25 1164.06 769.35 200.10
     2
        478.29 5496.27 1658.00
                                   887.03 1326.00
                                                     709.41 214.00
     3 1024.87 6972.82 1364.44 1072.06 1211.98
                                                     952.27 186.34
     4 1208.75 6042.66 1443.26
                                   991.25 1386.84
                                                     952.50 227.50
[17]: sns.set(style="whitegrid")
     fig, axes = plt.subplots(nrows=5, ncols=3, figsize=(24, 16))
     plt.subplots_adjust(hspace=0.5)
     sns.scatterplot(data=df2, x='M2', y='MR', ax=axes[0, 0])
     axes[0, 0].set_title('M2 vs MR')
```

```
sns.scatterplot(data=df2, x='W2', y='MR', ax=axes[0, 1])
axes[0, 1].set_title('W2 vs MR')
sns.scatterplot(data=df2, x='H2', y='MR', ax=axes[0, 2])
axes[1, 0].set_title('H2 vs MR')
sns.scatterplot(data=df2, x='P2', y='MR', ax=axes[1, 0])
axes[1, 0].set_title('P2 vs MR')
sns.scatterplot(data=df2, x='S2', y='MR', ax=axes[1, 1])
axes[1, 1].set title('S2 vs MR')
sns.scatterplot(data=df2, x='MW', y='MR', ax=axes[1, 2])
axes[2, 0].set_title('MW vs MR')
sns.scatterplot(data=df2, x='MH', y='MR', ax=axes[2, 0])
axes[2, 1].set_title('MH vs MR')
sns.scatterplot(data=df2, x='MP', y='MR', ax=axes[2, 1])
axes[2, 1].set_title('MP vs MR')
sns.scatterplot(data=df2, x='MS', y='MR', ax=axes[2, 2])
axes[3, 0].set_title('MS vs MR')
sns.scatterplot(data=df2, x='WH', y='MR', ax=axes[3, 0])
axes[3, 1].set_title('WH vs MR')
sns.scatterplot(data=df2, x='WP', y='MR', ax=axes[3, 1])
axes[3, 1].set_title('WP vs MR')
sns.scatterplot(data=df2, x='WS', y='MR', ax=axes[3, 2])
axes[4, 0].set_title('WS vs MR')
sns.scatterplot(data=df2, x='HP', y='MR', ax=axes[4, 0])
axes[4, 1].set_title('HP vs MR')
sns.scatterplot(data=df2, x='HS', y='MR', ax=axes[4, 1])
axes[4, 1].set_title('HS vs MR')
```

```
sns.scatterplot(data=df2, x='PS', y='MR', ax=axes[4, 2])
axes[4, 1].set_title('PS vs MR')

plt.tight_layout()
plt.show()
```



 $mse_2 = []$

```
mae_2 = []
r2_2 = []
for train_index, test_index in kf_2.split(x_2):
  # Training phase
 x_train = x_2[train_index, : ]
 y_train = y_2[train_index]
 regression = linear_model.LinearRegression()
 regression.fit(x_train, y_train)
  # Test phase
  x_{test} = x_{2}[test_{index}, :]
 y_test = y_2[test_index]
 y_predict2 = regression.predict(x_test)
  # Calculate MSE, MAE & R^2
 mse_i = mean_squared_error(y_test, y_predict2)
 mse_2.append(mse_i)
 mae_i = mean_absolute_error(y_test, y_predict2)
 mae_2.append(mae_i)
 r2_i = r2_score(y_test, y_predict2)
 r2_2.append(r2_i)
print('MSE:', np.average(mse_2), ' MAE:', np.average(mae_2), ' R^2:', np.
 →average(r2_2))
```

MSE: 21.876113316382938 MAE: 2.609859236284243 R^2: 0.2716651166324015

Implementa regresión Ridge con descenso de gradiente, y genera el gráfico de Ridge para el conjunto de datos original (sin las variables elevadas al cuadrado).

```
[22]: # Error function (it evaluates the mean squared error function for the
      →specified model and data set).
      def mse(X, y, beta):
       y_pred = X @ beta
       return (y - y_pred).sum()
      # Gradient of error function (it evaluates the gradient of the mean squared
       ⇔error function for the specified model and data set).
      def grad(X, y, beta, lambd):
       n = len(y)
       y_pred = X @ beta
       res = y - y_pred
       tmp = res*X.transpose()
       return -(2/n)*tmp.sum(axis = 1) + 2*lambd*beta
      def fit_modelRidge(x,y,lambd = 0.1, alpha = 0.0005, maxit = 100000):
       npredictors = x.shape[1]
       beta = 2 * np.random.rand(npredictors)-1.0
        it = 0
        while (np.linalg.norm(grad(x,y,beta,lambd)) > 1e-4) and (it < maxit):
```

```
beta = beta - alpha*grad(x,y,beta,lambd)
it = it + 1
return beta
```

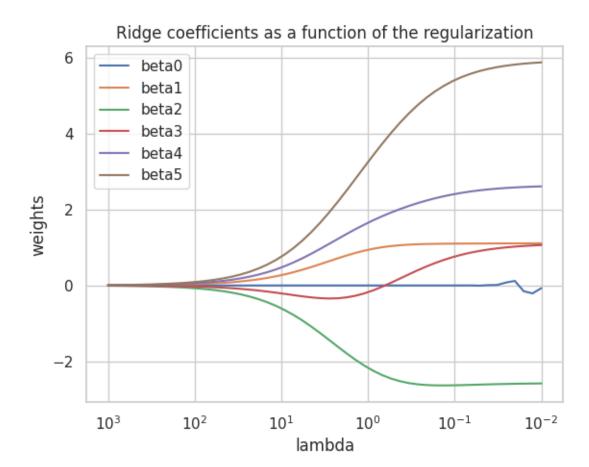
```
[23]: lambdas = np.logspace(-2,3,50)
    coefs=[]

scaler = StandardScaler()
x_normalized = scaler.fit_transform(x)
for l in lambdas:
    betaR = fit_modelRidge(x_normalized,y,l)
    coefs.append(betaR)
```

```
[24]: axis = plt.gca()
    lineObjects = axis.plot(lambdas, coefs)
    axis.set_xscale('log')
    axis.set_xlim(axis.get_xlim()[::-1])
    plt.xlabel('lambda')
    plt.ylabel('weights')
    plt.title('Ridge coefficients as a function of the regularization')
    plt.axis('tight')

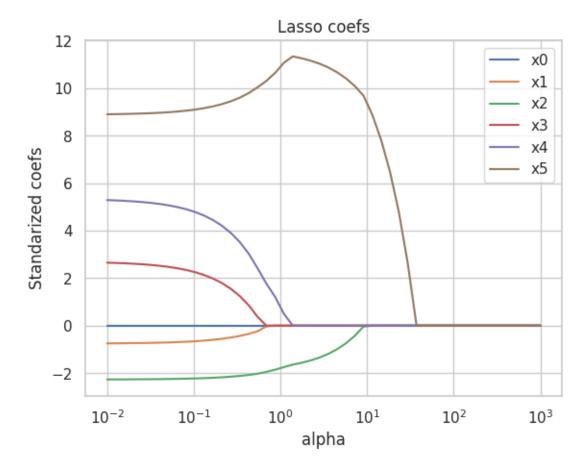
features = ['beta' + str(feat) for feat in range(coefs[0].shape[0])]
    axis.legend(iter(lineObjects), features)

plt.show()
```



Utiliza una librería para generar el gráfico de Lasso para el conjunto de datos original (sin las variables elevadas al cuadrado). ¿Qué variables son más relevantes para el modelo?

```
axis.set_xlim(axis.get_xlim()[::-1])
plt.axis('tight')
plt.xlabel('alpha')
plt.ylabel('Standarized coefs')
plt.title('Lasso coefs')
features = ['x' + str(feat) for feat in range(coefs[0].shape[0])]
ax.legend(iter(lineObjects), features)
plt.show()
```



- ¿Consideras que el modelo de regresión lineal es efectivo para modelar los datos del problema? ¿Por qué? El modelo de regresion lineal no es efectivo para modelar los datos del problema ya que al momento de sacar R2 nos da un valor negativo y por encima de 1. Esto quiere decir que en el modelo lineal no obtendremos un resultado ajustado segun las caracteristicas de nuestros datos y que deberiams considerar otro tipo de modelo.
- ¿Observas una variabilidad importante en los valores de R2, MSE y MAE cuando aplicas validación cruzada? Detalla tu respuesta. En validación cruzada, los valores de R2 toman mayor sentido ya que, a pesar de mostrar un resultado de ajuste del 0.27 (reflejando un ajuste del modelo pobre), dicho resultado cobra mayor sentido que en comapracion a usar un modelo de regresion lineal donde R2 tiene un resultado fuera de lugar en base a nuestros datos. En

cuanto a MSE y MAE la variabilidad es minima en comparacion con el modelo lineal y de validacion cruzada, siendo el ultimo quien toma valores un poco por encima que el del lineal pero aun asi, dando resultados muy parecidos entre si.

- ¿Qué modelo es mejor para los datos de criminalidad, el lineal o el cuadrático? ¿Por qué? En este caso es mejor el mejor modelo cuadratico ya que aqui no consideramos realmente R2 y ademas, considerando las preguntas anteriores, R2 no tuvo sentido en el modelo lineal por lo que el mejor modelo a utilizar es el cuadratico. Aunque el modelo cuadratico tuvo un ajuste muy pobre, es visiblemente mejor al lineal por ese simple aspecto, ya que tambien mencionamos que la variabilidad entre MSE y MAE en ambos modelos es minima.
- ¿Qué variables son más relevantes para el modelo según Ride y Lasso? En Ride tenemos como variables relevantes a: M, H, P y S; mientras que en Lasso tenemos como variables relevantes a: H, P y S. Tambien a considerar que MR es una variable que se mantiene constante en valores de 0 por lo que no es relevante; al igual que M y W que en los diferentes modelos tienen valores por debajo de 0.
- ¿Encuentras alguna relación interesante entre la variable de respuesta y los predictores? Una relacion es que tanto las variables H, P y S son variables relevantes en ambos modelos y MR se mantiene como una variable constante con valor a 0, ademas, en ambos modelos se suelen o empezar o terminar todas las variables desde un mismo punto dependiendo el tipo de modelo.

##Ejercicio 2

El conjunto de datos de esperanzas de vida (*Life Expectancy (WHO) | Kaggle*) tiene el registro de la esperanza de vida de 193 países medida en diferentes años, junto con otras variables que se pueden relacionar con riesgos a la salud y la mortalidad. Para este ejercicio, sólo se considerará como variable dependiente la cuarta columna ("Life expectancy"). A su vez, las variables independientes de interés son:

- X1 Adult mortality
- X2 Infant deaths
- X3 Alcohol
- X4 Percentage expenditure
- X5 Hepatitis B
- X6 Measles
- X7 BMI
- X8 Under-five deaths
- X9 Polio
- X10 Total expenditure
- X11 Diphtheria
- X12 HIV/AIDS
- X13 GDP
- X14 Population
- X15 Thinness 1-19 years
- X16 Thinness 5-9 years
- X17 Income composition of resources
- X18 Schooling

Consideraciones: * Penúltimo número de matrícula: 1 * Todas las variables, menos X1, X5, X9, X13, X17

```
[26]: df2 = pd.read_csv('/content/sample_data/life_expectancy_data.csv')
      df2.head()
[26]:
             Country Year
                                Status Life expectancy
                                                           Adult Mortality \
         Afghanistan 2015
                                                     65.0
                                                                      263.0
                           Developing
      1 Afghanistan
                      2014
                            Developing
                                                     59.9
                                                                      271.0
      2 Afghanistan
                     2013
                            Developing
                                                     59.9
                                                                     268.0
      3 Afghanistan 2012
                            Developing
                                                     59.5
                                                                      272.0
      4 Afghanistan 2011 Developing
                                                     59.2
                                                                     275.0
         infant deaths Alcohol percentage expenditure Hepatitis B Measles
      0
                           0.01
                                               71.279624
                                                                 65.0
                                                                            1154
                    62
                           0.01
                                               73.523582
                                                                 62.0
      1
                    64
                                                                             492
                                               73.219243
      2
                    66
                           0.01
                                                                 64.0
                                                                             430 ...
      3
                    69
                           0.01
                                               78.184215
                                                                 67.0
                                                                            2787
      4
                    71
                           0.01
                                                7.097109
                                                                 68.0
                                                                            3013 ...
                Total expenditure Diphtheria
                                                  HIV/AIDS
                                                                   GDP
                                                                        Population \
         Polio
           6.0
                             8.16
                                           65.0
                                                       0.1 584.259210
                                                                         33736494.0
      0
          58.0
                             8.18
                                           62.0
      1
                                                       0.1 612.696514
                                                                           327582.0
          62.0
                             8.13
                                           64.0
                                                       0.1 631.744976
                                                                        31731688.0
      2
          67.0
                             8.52
                                           67.0
                                                       0.1 669.959000
      3
                                                                          3696958.0
          68.0
                             7.87
                                           68.0
                                                       0.1
                                                             63.537231
                                                                          2978599.0
          thinness 1-19 years
                                 thinness 5-9 years
      0
                          17.2
                                                17.3
      1
                          17.5
                                                17.5
      2
                          17.7
                                                17.7
      3
                          17.9
                                                18.0
      4
                          18.2
                                                18.2
         Income composition of resources
                                         Schooling
      0
                                   0.479
                                                10.1
      1
                                   0.476
                                                10.0
      2
                                   0.470
                                                 9.9
      3
                                   0.463
                                                 9.8
                                   0.454
                                                 9.5
      [5 rows x 22 columns]
[27]: df2.isnull().sum()
[27]: Country
                                            0
      Year
                                            0
      Status
                                            0
      Life expectancy
                                           10
      Adult Mortality
                                           10
```

```
Alcohol
                                           194
      percentage expenditure
                                            0
                                          553
      Hepatitis B
      Measles
                                            0
       BMT
                                            34
      under-five deaths
                                            0
      Polio
                                            19
      Total expenditure
                                          226
      Diphtheria
                                            19
       HIV/AIDS
                                            0
      GDP
                                          448
      Population
                                          652
       thinness 1-19 years
                                           34
       thinness 5-9 years
                                           34
      Income composition of resources
                                          167
                                          163
      Schooling
      dtype: int64
[28]: df2 = df2.dropna()
      df_status = df2
[29]: df2 = df2.drop(columns=['Country', 'Year', 'Status', 'Adult Mortality', 'Hepatitis_
       ⇔B', 'Polio', 'GDP', 'Income composition of resources'], axis=1)
      df2.head()
[29]:
         Life expectancy
                            infant deaths Alcohol percentage expenditure Measles
      0
                      65.0
                                       62
                                               0.01
                                                                  71.279624
                                                                                  1154
      1
                     59.9
                                       64
                                               0.01
                                                                  73.523582
                                                                                   492
      2
                     59.9
                                       66
                                               0.01
                                                                  73.219243
                                                                                   430
      3
                     59.5
                                       69
                                               0.01
                                                                   78.184215
                                                                                  2787
      4
                     59.2
                                       71
                                               0.01
                                                                    7.097109
                                                                                  3013
          BMI
                under-five deaths
                                     Total expenditure Diphtheria
                                                                       HIV/AIDS \
                                                                65.0
      0
          19.1
                                                   8.16
                                                                             0.1
                                 83
          18.6
                                 86
                                                   8.18
                                                                62.0
                                                                             0.1
      1
      2
          18.1
                                                                64.0
                                 89
                                                   8.13
                                                                             0.1
          17.6
                                                   8.52
                                                                67.0
      3
                                 93
                                                                             0.1
      4
          17.2
                                 97
                                                   7.87
                                                                68.0
                                                                             0.1
         Population
                       thinness 1-19 years
                                               thinness 5-9 years Schooling
      0 33736494.0
                                       17.2
                                                             17.3
                                                                         10.1
           327582.0
                                       17.5
                                                             17.5
                                                                         10.0
      1
                                       17.7
                                                             17.7
                                                                          9.9
      2 31731688.0
                                       17.9
                                                             18.0
                                                                          9.8
      3
          3696958.0
          2978599.0
                                       18.2
                                                             18.2
                                                                          9.5
```

0

infant deaths

1. Evalúa con validación cruzada un modelo de regresión lineal para las variables asignadas según tu matrícula utilizando alguna librería o framework.

```
[31]: from sklearn.model_selection import cross_val_score
    from sklearn.linear_model import LinearRegression
    from sklearn.feature_selection import SelectKBest, r_regression,f_regression
    # Creamomos el modelo de regresión lineal
    model = LinearRegression()

# Realizamos validación cruzada y obtener el score R2
    scores = cross_val_score(model, x_life, y_life, cv=10, scoring='r2')

# Imprimir los scores de la validación cruzada
    print("Scores X-Validation:", scores)
    print("\nScore Average:", scores.mean())
```

Scores X-Validation: [0.63850221 0.83347992 0.72799955 0.77049716 0.63338871 0.80962943 0.58534305 0.73552998 0.58040315 0.81338127]

Score Average: 0.7128154437625017

```
[32]: # Evaluamos con validación cruzada
from sklearn.model_selection import KFold
from sklearn.feature_selection import SelectKBest
from sklearn import linear_model
from sklearn.metrics import mean_squared_error, mean_absolute_error, r2_score
import numpy as np

folds_life = 10
kf_life = KFold(n_splits=folds_life, shuffle=True)
mse_cv = []
mae_cv = []
r2_cv = []

for train_index, test_index in kf_life.split(x_life):
    # Training phase
    x_train = x_life[train_index, :]
    y_train = y_life[train_index]
```

```
fselectionCV = SelectKBest(r_regression,k=folds_life) # Choose the_
 \rightarrowappropriate value of k
    fselectionCV.fit(x_train, y_train)
    X_train = fselectionCV.transform(x_train)
    regrCV = linear model.LinearRegression()
    regrCV.fit(X_train, y_train)
    # Test phase
    x_test = fselectionCV.transform(x_life[test_index, :])
    y_test = y_life[test_index]
    y_pred = regrCV.predict(x_test)
    # Calculate MSE, MAE and R^2
    mse_i = mean_squared_error(y_test, y_pred)
    mse_cv.append(mse_i)
    mae_i = mean_absolute_error(y_test, y_pred)
    mae_cv.append(mae_i)
    r2_i = r2_score(y_test, y_pred)
    r2_cv.append(r2_i)
print('MSE:', np.average(mse_cv), 'MAE:', np.average(mae_cv), 'R^2:', np.
 →average(r2_cv))
```

MSE: 30.197963532652455 MAE: 4.140698776687403 R^2: 0.6081965638088977

1. Encuentra el número óptimo de predictores para el modelo utilizando el método filter y validación cruzada. Una vez que tengas el número óptimo, muestra las características seleccionadas.

```
[33]: # Encontrar el número óptimo de características mediante validación cruzada
      nFeats = [1,2,3,4,5,6,7,8,9]
      mseNfeat = \Pi
      maeNfeat = []
      r_2Nfeat = []
      selected_features = []
      for nFeat in nFeats:
        print('---- Num. de Característica: ', nFeat)
        mseCV = []
        maeCV = []
        r2CV = []
        kf = KFold(n_splits=10, shuffle=True)
        for train_index, test_index in kf.split(x_life):
          # Entrenamiento
          X_train = x_life[train_index, :]
          y_train = y_life[train_index]
          fselectionCV = SelectKBest(r_regression, k=nFeat)
```

```
fselectionCV.fit(X_train, y_train)
    X_train = fselectionCV.transform(X_train)
    regrCV = linear_model.LinearRegression()
    regrCV.fit(X_train, y_train)
    selected_features.append(fselectionCV.get_feature_names_out())
    # Prueba
    x_test = fselectionCV.transform(x_life[test_index, :])
    y_test = y_life[test_index]
    y_pred = regrCV.predict(x_test)
    mse_i = mean_squared_error(y_test, y_pred)
    mseCV.append(mse_i)
    mae_i = mean_absolute_error(y_test, y_pred)
    maeCV.append(mae_i)
    r2_i = r2_score(y_test, y_pred)
   r2CV.append(r2_i)
 mse = np.average(mseCV)
  mseNfeat.append(mse)
 mae = np.average(maeCV)
 maeNfeat.append(mae)
 r2 = np.average(r2CV)
 r 2Nfeat.append(r2)
 print('MSE:', mse, ' MAE:', mae, ' R^2:', r2)
opt_feat = nFeats[np.argmin(mseNfeat)]
opt_sel_ind = selected_features[opt_feat - 1]
print("\nNúmero óptimo de caracteríatcas: ", opt_feat)
print("Caracteríasticas: ", opt_sel_ind, '\n')
fig, axs = plt.subplots(1, 3, tight_layout=True)
axs[0].plot(nFeats, mseNfeat)
axs[0].set_xlabel("k")
axs[0].set_ylabel("MSE")
axs[1].plot(nFeats, maeNfeat)
axs[1].set xlabel("k")
axs[1].set_ylabel("MAE")
axs[2].plot(nFeats, r 2Nfeat)
axs[2].set_xlabel("k")
axs[2].set_ylabel("r^2")
plt.show()
```

```
---- Num. de Característica: 1
MSE: 36.54451792639633 MAE: 4.562372688328573 R^2: 0.5215066392714365
```

---- Num. de Característica: 2

MSE: 34.376393166450654 MAE: 4.468333449055066 R^2: 0.5522925292239403

---- Num. de Característica: 3

MSE: 33.5450246125486 MAE: 4.404732112771983 R^2: 0.5648830847584749

---- Num. de Característica: 4

MSE: 32.8610262874218 MAE: 4.3681035836772875 R^2: 0.5713552289423719

---- Num. de Característica: 5

MSE: 32.07630334340262 MAE: 4.30800444889095 R^2: 0.5835056001938328

---- Num. de Característica: 6

MSE: 32.242542985857675 MAE: 4.321568636837964 R^2: 0.5801316567833451

---- Num. de Característica: 7

MSE: 32.11435789555017 MAE: 4.314164711027673 R^2: 0.5825142620835096

---- Num. de Característica: 8

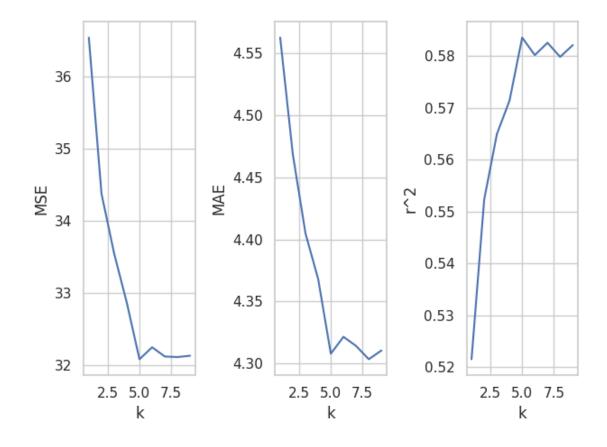
MSE: 32.10623016356467 MAE: 4.303530549938605 R^2: 0.5797913836972162

---- Num. de Característica: 9

MSE: 32.12518080932987 MAE: 4.310588987402607 R^2: 0.582063409973031

Número óptimo de caracteríatcas: 5

Caracteríasticas: ['x12']



3. Repite el paso anterior pero con selección de características secuencial (Wrapper). Reporta los predictores óptimos encontrados por el método.

```
[34]: from sklearn.feature_selection import SelectKBest, r_regression,_
       →SequentialFeatureSelector, RFE
      from sklearn.ensemble import RandomForestRegressor
      n_{feats} = [1, 2, 3, 4, 5, 6, 7, 8, 9]
      mse nfeat = []
      mae_nfeat = []
      r2 nfeat = []
      selected_features = []
      for n_feat in n_feats:
          print('---- Num. de Característica: ', n_feat)
          mse_cv = []
          mae_cv = []
          r2_cv = []
          kf = KFold(n_splits=10, shuffle=True)
          for train_index, test_index in kf.split(x_life):
              # Training phase
              x_train = x_life[train_index, :]
              y_train = y_life[train_index]
              # Initialize the linear regression model
              regr_cv = linear_model.LinearRegression()
              # Initialize SequentialFeatureSelector
              fselection_cv = SequentialFeatureSelector(regr_cv,
                                                         n_features_to_select=n_feat,
                                                         direction='forward')
              fselection_cv.fit(x_train, y_train)
              # Get selected feature indices
              selected_indices = fselection_cv.get_support(indices=True)
              selected_features.append(selected_indices)
              # Transform the training data
              x_train_selected = fselection_cv.transform(x_train)
              # Fit the model
              regr_cv.fit(x_train_selected, y_train)
              # Test phase
              x_test = x_life[test_index, :]
              y_test = y_life[test_index]
```

```
# Transform the test data
        x_test_selected = fselection_cv.transform(x_test)
        y_pred = regr_cv.predict(x_test_selected)
        mse_i = mean_squared_error(y_test, y_pred)
        mse_cv.append(mse_i)
        mae_i = mean_absolute_error(y_test, y_pred)
        mae_cv.append(mae_i)
        r2_i = r2_score(y_test, y_pred)
        r2_cv.append(r2_i)
    mse = np.average(mse_cv)
    mse nfeat.append(mse)
    mae = np.average(mae_cv)
    mae_nfeat.append(mae)
    r2 = np.average(r2_cv)
    r2_nfeat.append(r2)
    print('MSE:', mse, ' MAE:', mae, ' R^2:', r2)
optimal_n_feat = n_feats[np.argmin(mse_nfeat)]
optimal_selected_indices = selected_features[optimal_n_feat - 1]
print("\nNúmero óptimo de características:", optimal_n_feat)
print("Características seleccionadas:", optimal_selected_indices,'\n')
fig, axs = plt.subplots(1, 3, tight_layout=True)
axs[0].plot(n feats, mse nfeat)
axs[0].set_xlabel("features")
axs[0].set_ylabel("MSE")
axs[1].plot(n_feats, mae_nfeat)
axs[1].set_xlabel("features")
axs[1].set_ylabel("MAE")
axs[2].plot(n_feats, r2_nfeat)
axs[2].set_xlabel("features")
axs[2].set_ylabel("r^2")
plt.show()
---- Num. de Característica: 1
MSE: 36.430565462772435 MAE: 4.554040532974198 R^2: 0.5286741828684388
---- Num. de Característica: 2
MSE: 20.968609419822275 MAE: 3.616115535744181 R^2: 0.7270997634647707
---- Num. de Característica: 3
MSE: 19.897794653259147 MAE: 3.5210742891448974 R^2: 0.7393725454824153
---- Num. de Característica: 4
MSE: 19.090612500490735 MAE: 3.4355898976777355 R^2: 0.7496809144478214
---- Num. de Característica: 5
MSE: 18.67915625073901 MAE: 3.408701078797113 R^2: 0.7556830126281291
---- Num. de Característica: 6
```

```
MSE: 18.62770394647907 MAE: 3.400667780564011 R^2: 0.7576945591259919
```

---- Num. de Característica: 7

MSE: 18.73914553754846 MAE: 3.4163753271611332 R^2: 0.7545397839671945

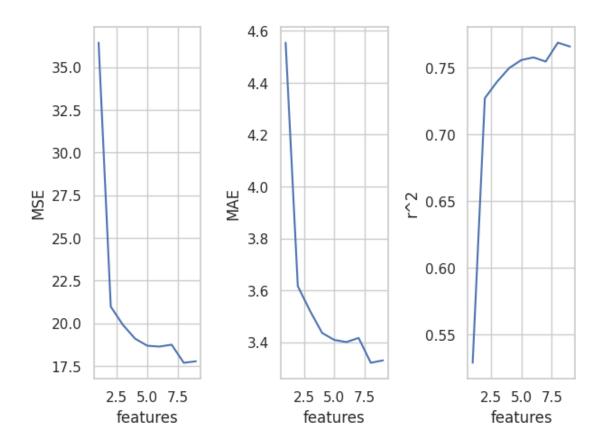
---- Num. de Característica: 8

MSE: 17.677143172312277 MAE: 3.3206010800600416 R^2: 0.7687087332613132

---- Num. de Característica: 9

MSE: 17.765899036639524 MAE: 3.329975921373202 R^2: 0.765797074114607

Número óptimo de características: 8 Características seleccionadas: [12]

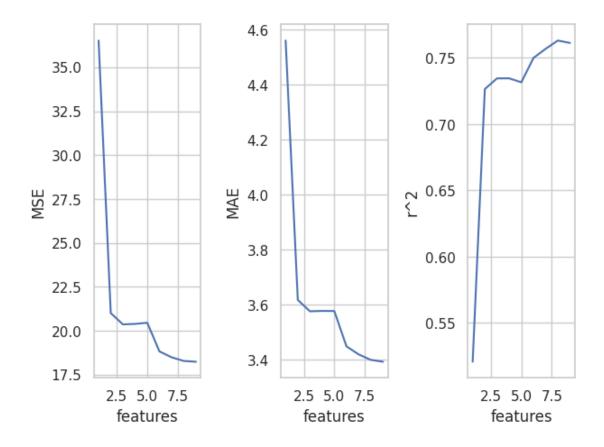


4. Haz el mismo proceso del paso 2, pero ahora con el método de selección de características recursivo (Filter-Wrapper). Reporta los predictores óptimos encontrados por el método.

```
[35]: # Find optimal number of features using cross-validation
n_feats = [1, 2, 3, 4, 5, 6, 7, 8, 9]
mse_nfeat = []
mae_nfeat = []
r2_nfeat = []
```

```
for n_feat in n_feats:
  print('---- n features =', n_feat)
 mse_cv = []
 mae_cv = []
 r2_cv = []
 kf = KFold(n_splits=10, shuffle = True)
  for train_index, test_index in kf.split(x_life):
    # Training phase
    x_train = x_life[train_index, :]
    y_train = y_life[train_index]
    regr_cv = LinearRegression()
    fselection_cv = RFE(regr_cv, n_features_to_select=n_feat)
    fselection_cv.fit(x_train, y_train)
    x_train = fselection_cv.transform(x_train)
    regr_cv.fit(x_train, y_train)
    # Test phase
    x_test = fselection_cv.transform(x_life[test_index, :])
    y_test = y_life[test_index]
    y_pred = regr_cv.predict(x_test)
    mse_i = mean_squared_error(y_test, y_pred)
    mse_cv.append(mse_i)
    mae_i = mean_absolute_error(y_test, y_pred)
    mae_cv.append(mae_i)
   r2 i = r2 score(y test, y pred)
   r2 cv.append(r2 i)
  mse = np.average(mse cv)
  mse_nfeat.append(mse)
 mae = np.average(mae_cv)
 mae_nfeat.append(mae)
 r2 = np.average(r2_cv)
 r2_nfeat.append(r2)
  print('MSE:', mse, ' MAE:', mae,' R^2:', r2)
# Imprime los resultados
print("\nNúmero óptimo de características (MSE):", n feats[np.
 →argmin(mse_nfeat)])
print("Número óptimo de características (MAE):", n_feats[np.argmin(mae_nfeat)])
print("Número óptimo de características (R^2):", n_feats[np.
 →argmax(r2_nfeat)],'\n')
fig, axs = plt.subplots(1, 3, tight_layout=True)
axs[0].plot(n_feats, mse_nfeat)
axs[0].set_xlabel("features")
axs[0].set_ylabel("MSE")
axs[1].plot(n_feats, mae_nfeat)
axs[1].set_xlabel("features")
axs[1].set_ylabel("MAE")
```

```
axs[2].plot(n_feats, r2_nfeat)
axs[2].set_xlabel("features")
axs[2].set_ylabel("r^2")
plt.show()
---- n features = 1
MSE: 36.5191719061063 MAE: 4.5610025997731665 R^2: 0.5207119333363225
---- n features = 2
MSE: 21.003532937044035 MAE: 3.617187743476349 R^2: 0.7264829415292431
---- n features = 3
MSE: 20.35852403847533 MAE: 3.5758612908499514 R^2: 0.7345220118408612
---- n features = 4
MSE: 20.388716168477686 MAE: 3.577288734742422 R^2: 0.7345641133049856
---- n features = 5
MSE: 20.452938461640066 MAE: 3.576837426706463 R^2: 0.7315701166504194
---- n features = 6
MSE: 18.8227143804498 MAE: 3.4483526986601603 R^2: 0.7499676356003394
---- n features = 7
MSE: 18.487734982949803 MAE: 3.419105524881803 R^2: 0.7568438271586307
---- n features = 8
MSE: 18.27896247454629 MAE: 3.399190027808713 R^2: 0.7630667522544259
---- n features = 9
MSE: 18.23315352484817 MAE: 3.3923226946760607 R^2: 0.7612511788414859
Número óptimo de características (MSE): 9
Número óptimo de características (MAE): 9
Número óptimo de características (R^2): 8
```



5. Repita los pasos anteriores, pero utilizando un modelo de regresión no lineal como K-vecinos más cercanos.

```
[36]: from sklearn.neighbors import KNeighborsRegressor

model = KNeighborsRegressor()

# Realizamos validación cruzada y obtener el score R2
scores = cross_val_score(model, x_life, y_life, cv=10, scoring='r2')

# Imprimir los scores de la validación cruzada
print("Scores X-Validation:", scores)
print("\nScore Average:", scores.mean())
```

Scores X-Validation: [-0.34837127 -0.35864655 -0.65610874 -0.20938524 -0.32160116 -0.05103129 -0.16748946 -1.21785562 -0.2515547 0.01048042]

Score Average: -0.35715636104571163

```
[37]: kf_life = KFold(n_splits=folds_life, shuffle=True)
      mse_cv = []
      mae_cv = []
      r2_cv = []
      for train_index, test_index in kf_life.split(x_life):
          # Training phase
          x_train = x_life[train_index, :]
          y_train = y_life[train_index]
          fselectionCV = SelectKBest(r regression,k=folds life) # Choose the
       \rightarrowappropriate value of k
          fselectionCV.fit(x_train, y_train)
          X_train = fselectionCV.transform(x_train)
          regrCV = KNeighborsRegressor()
          regrCV.fit(X_train, y_train)
          # Test phase
          x_test = fselectionCV.transform(x_life[test_index, :])
          y_test = y_life[test_index]
          y_pred = regrCV.predict(x_test)
          # Calculate MSE, MAE and R^2
          mse_i = mean_squared_error(y_test, y_pred)
          mse_cv.append(mse_i)
          mae_i = mean_absolute_error(y_test, y_pred)
          mae_cv.append(mae_i)
          r2_i = r2_score(y_test, y_pred)
          r2_cv.append(r2_i)
      print('MSE:', np.average(mse_cv), 'MAE:', np.average(mae_cv), 'R^2:', np.
       →average(r2_cv))
```

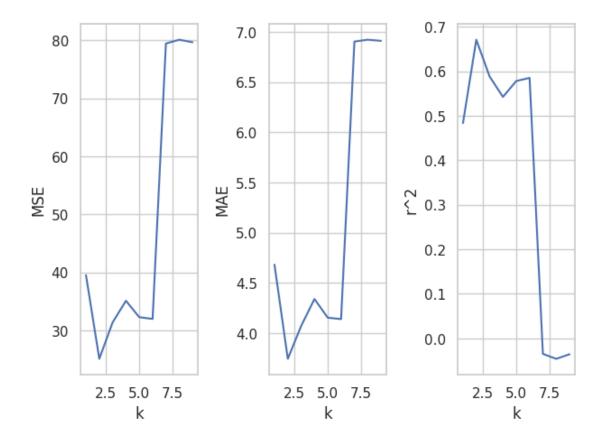
MSE: 79.21145174870658 MAE: 6.899344715447155 R^2: -0.0333883543847728

```
[38]: nFeats = [1,2,3,4,5,6,7,8,9]
   mseNfeat = []
   maeNfeat = []
   r_2Nfeat = []
   selected_features = []

   for nFeat in nFeats:
      print('---- Num. de Característica: ', nFeat)
      mseCV = []
      maeCV = []
      r2CV = []
```

```
kf = KFold(n_splits=10, shuffle=True)
  for train_index, test_index in kf.split(x_life):
    # Entrenamiento
    X_train = x_life[train_index, :]
    y_train = y_life[train_index]
    fselectionCV = SelectKBest(r_regression, k=nFeat)
    fselectionCV.fit(X_train, y_train)
    X_train = fselectionCV.transform(X_train)
    regrCV = KNeighborsRegressor()
    regrCV.fit(X_train, y_train)
    selected_features.append(fselectionCV.get_feature_names_out())
    # Prueba
    x_test = fselectionCV.transform(x_life[test_index, :])
    y_test = y_life[test_index]
    y_pred = regrCV.predict(x_test)
    mse_i = mean_squared_error(y_test, y_pred)
    mseCV.append(mse_i)
    mae_i = mean_absolute_error(y_test, y_pred)
    maeCV.append(mae_i)
    r2_i = r2_score(y_test, y_pred)
    r2CV.append(r2_i)
  mse = np.average(mseCV)
 mseNfeat.append(mse)
 mae = np.average(maeCV)
 maeNfeat.append(mae)
 r2 = np.average(r2CV)
  r_2Nfeat.append(r2)
 print('MSE:', mse, ' MAE:', mae, ' R^2:', r2)
opt_feat = nFeats[np.argmin(mseNfeat)]
opt_sel_ind = selected_features[opt_feat - 1]
print("\nNúmero óptimo de caracteríatcas: ", opt_feat)
print("Caracteríasticas: ", opt_sel_ind, '\n')
fig, axs = plt.subplots(1, 3, tight_layout=True)
axs[0].plot(nFeats, mseNfeat)
axs[0].set_xlabel("k")
axs[0].set ylabel("MSE")
axs[1].plot(nFeats, maeNfeat)
axs[1].set_xlabel("k")
axs[1].set_ylabel("MAE")
axs[2].plot(nFeats, r_2Nfeat)
```

```
axs[2].set_xlabel("k")
axs[2].set_ylabel("r^2")
plt.show()
---- Num. de Característica: 1
MSE: 39.517368452328164 MAE: 4.6816535107169255 R^2: 0.4834798553375518
---- Num. de Característica: 2
MSE: 25.094517819660012 MAE: 3.74309453067258 R^2: 0.6707277066097309
---- Num. de Característica: 3
MSE: 31.376414585365854 MAE: 4.069816038433112 R^2: 0.5880247774489058
---- Num. de Característica: 4
MSE: 35.10187912638581 MAE: 4.339047819660014 R^2: 0.5422899741557491
---- Num. de Característica: 5
MSE: 32.27492109977827 MAE: 4.153330081300814 R^2: 0.5779291758821887
---- Num. de Característica: 6
MSE: 31.979471895048043 MAE: 4.139463488543977 R^2: 0.5849694123857452
---- Num. de Característica: 7
MSE: 79.4314977339246 MAE: 6.903569179600886 R^2: -0.034940541535298256
---- Num. de Característica: 8
MSE: 80.092142699187 MAE: 6.921971470805618 R^2: -0.04612645827615893
---- Num. de Característica: 9
MSE: 79.65076969549149 MAE: 6.910531929046563 R^2: -0.03573749274063402
Número óptimo de caracteríatcas: 2
Caracteríasticas: ['x12']
```



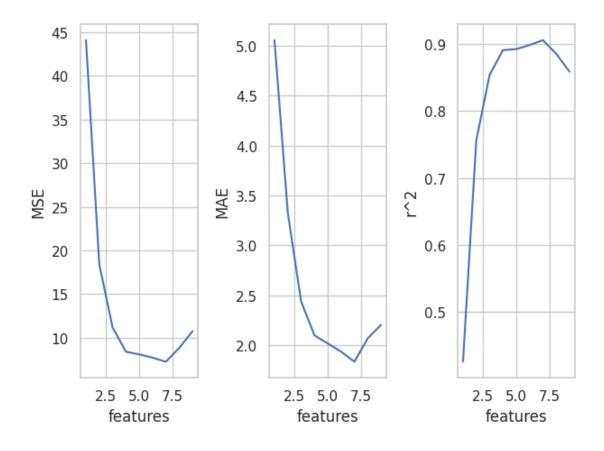
```
[39]: n_{feats} = [1, 2, 3, 4, 5, 6, 7, 8, 9]
      mse_nfeat = []
      mae_nfeat = []
      r2\_nfeat = []
      selected_features = []
      for n_feat in n_feats:
          print('---- Num. de Característica: ', n_feat)
          mse_cv = []
          mae_cv = []
          r2_cv = []
          kf = KFold(n_splits=10, shuffle=True)
          for train_index, test_index in kf.split(x_life):
              # Training phase
              x_train = x_life[train_index, :]
              y_train = y_life[train_index]
              # Initialize the linear regression model
              regr_cv = KNeighborsRegressor()
              # Initialize SequentialFeatureSelector
```

```
fselection_cv = SequentialFeatureSelector(regr_cv,
                                                  n_features_to_select=n_feat,
                                                  direction='forward')
        fselection_cv.fit(x_train, y_train)
        # Get selected feature indices
        selected_indices = fselection_cv.get_support(indices=True)
        selected_features.append(selected_indices)
        # Transform the training data
        x_train_selected = fselection_cv.transform(x_train)
        # Fit the model
       regr_cv.fit(x_train_selected, y_train)
        # Test phase
       x_test = x_life[test_index, :]
       y_test = y_life[test_index]
        # Transform the test data
       x_test_selected = fselection_cv.transform(x_test)
       y_pred = regr_cv.predict(x_test_selected)
       mse_i = mean_squared_error(y_test, y_pred)
       mse_cv.append(mse_i)
       mae_i = mean_absolute_error(y_test, y_pred)
       mae_cv.append(mae_i)
       r2_i = r2_score(y_test, y_pred)
       r2_cv.append(r2_i)
   mse = np.average(mse_cv)
   mse_nfeat.append(mse)
   mae = np.average(mae_cv)
   mae_nfeat.append(mae)
   r2 = np.average(r2_cv)
   r2_nfeat.append(r2)
   print('MSE:', mse, ' MAE:', mae, ' R^2:', r2)
optimal n feat = n feats[np.argmin(mse nfeat)]
optimal_selected_indices = selected_features[optimal_n_feat - 1]
print("\nNúmero óptimo de características:", optimal_n_feat)
print("Características seleccionadas:", optimal_selected_indices,'\n')
fig, axs = plt.subplots(1, 3, tight_layout=True)
axs[0].plot(n_feats, mse_nfeat)
axs[0].set_xlabel("features")
axs[0].set_ylabel("MSE")
```

```
axs[1].plot(n_feats, mae_nfeat)
axs[1].set_xlabel("features")
axs[1].set_ylabel("MAE")
axs[2].plot(n_feats, r2_nfeat)
axs[2].set_xlabel("features")
axs[2].set_ylabel("r^2")
plt.show()
```

```
---- Num. de Característica: 1
MSE: 44.0802340473023 MAE: 5.054528085735402 R^2: 0.4259718740405292
---- Num. de Característica: 2
MSE: 18.384166056171466 MAE: 3.3256197339246123 R^2: 0.7563574781822384
---- Num. de Característica: 3
MSE: 11.155943488543974 MAE: 2.439387287509239 R^2: 0.8538916417108162
---- Num. de Característica: 4
MSE: 8.38895993348115 MAE: 2.0999804138950475 R^2: 0.8908023853194015
---- Num. de Característica: 5
MSE: 8.079096379896525 MAE: 2.018064375461937 R^2: 0.8923798359490066
---- Num. de Característica: 6
MSE: 7.708214410938654 MAE: 1.9361042867701403 R^2: 0.8984336390178917
---- Num. de Característica: 7
MSE: 7.241505053954175 MAE: 1.8351900221729491 R^2: 0.9056443524592452
---- Num. de Característica: 8
MSE: 8.822908338507023 MAE: 2.0695161123429413 R^2: 0.8853714995426211
---- Num. de Característica: 9
MSE: 10.752362545454545 MAE: 2.204680266075388 R^2: 0.8586006508470888
```

Número óptimo de características: 7 Características seleccionadas: [4]

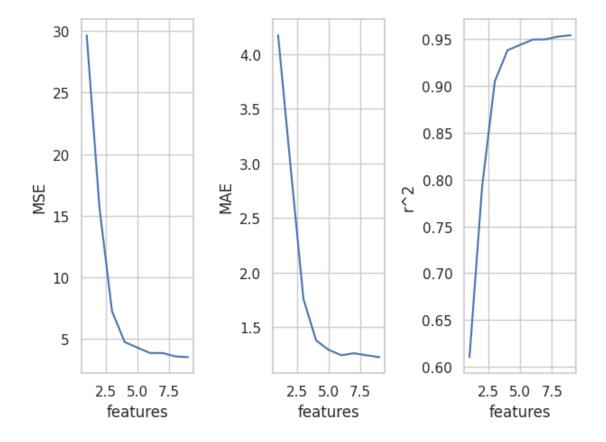


```
[40]: # Find optimal number of features using cross-validation
      n_{feats} = [1, 2, 3, 4, 5, 6, 7, 8, 9]
      mse_nfeat = []
      mae_nfeat = []
      r2\_nfeat = []
      for n_feat in n_feats:
        print('---- n features =', n_feat)
       mse_cv = []
        mae_cv = []
        r2_cv = []
        kf = KFold(n_splits=10, shuffle = True)
        for train_index, test_index in kf.split(x_life):
          # Training phase
          x_train = x_life[train_index, :]
          y_train = y_life[train_index]
          regr_cv = RandomForestRegressor()
          fselection_cv = RFE(regr_cv, n_features_to_select=n_feat)
          fselection_cv.fit(x_train, y_train)
          x_train = fselection_cv.transform(x_train)
          regr_cv.fit(x_train, y_train)
```

```
# Test phase
    x_test = fselection_cv.transform(x_life[test_index, :])
    y_test = y_life[test_index]
    y_pred = regr_cv.predict(x_test)
    mse_i = mean_squared_error(y_test, y_pred)
    mse_cv.append(mse_i)
    mae_i = mean_absolute_error(y_test, y_pred)
    mae_cv.append(mae_i)
    r2_i = r2_score(y_test, y_pred)
    r2_cv.append(r2_i)
  mse = np.average(mse cv)
  mse_nfeat.append(mse)
  mae = np.average(mae_cv)
  mae_nfeat.append(mae)
  r2 = np.average(r2_cv)
  r2_nfeat.append(r2)
  print('MSE:', mse, ' MAE:', mae,' R^2:', r2)
# Imprime los resultados
print("\nNúmero óptimo de características (MSE):", n_feats[np.
  →argmin(mse_nfeat)])
print("Número óptimo de características (MAE):", n feats[np.argmin(mae nfeat)])
print("Número óptimo de características (R^2):", n_feats[np.
 ⇒argmax(r2_nfeat)],'\n')
fig, axs = plt.subplots(1, 3, tight_layout=True)
axs[0].plot(n feats, mse nfeat)
axs[0].set xlabel("features")
axs[0].set_ylabel("MSE")
axs[1].plot(n_feats, mae_nfeat)
axs[1].set_xlabel("features")
axs[1].set ylabel("MAE")
axs[2].plot(n_feats, r2_nfeat)
axs[2].set xlabel("features")
axs[2].set_ylabel("r^2")
plt.show()
---- n features = 1
MSE: 29.65327690068303 MAE: 4.171743102115355 R^2: 0.6104324982713394
---- n features = 2
MSE: 15.724144577720285 MAE: 2.951448558877659 R^2: 0.7929090690573114
---- n features = 3
MSE: 7.250728652277343 MAE: 1.760106686307655 R^2: 0.9048095264673537
---- n features = 4
MSE: 4.756107935665554 MAE: 1.3806508879437165 R^2: 0.9379229382853206
---- n features = 5
MSE: 4.302947693487483 MAE: 1.2933709511141616 R^2: 0.9436521897040718
```

```
---- n features = 6
MSE: 3.867329309773465 MAE: 1.2447870102065957 R^2: 0.9492920407223615
---- n features = 7
MSE: 3.8644985400221734 MAE: 1.2628853436807106 R^2: 0.9496099725453282
---- n features = 8
MSE: 3.5912636953288994 MAE: 1.2441726090170002 R^2: 0.9524776420774188
---- n features = 9
MSE: 3.529743269449374 MAE: 1.227335229120474 R^2: 0.9539741641918893

Número óptimo de características (MSE): 9
Número óptimo de características (MAE): 9
Número óptimo de características (R^2): 9
```



6. Agregue la variables "Status" (segunda columna) como variable predictora, y utiliza un árbol de decisión para generar un modelo de regresión para la varible Life expectancy". Evalúa este modelo con validación cruzada utilizando la métrica adecuada.

```
[41]: df_status.columns df_status.drop(columns=['Country','Life expectancy ','Year','Adult_

→Mortality','Hepatitis B','Polio','GDP','Income composition of resources'],

→axis=1)
```

```
[41]:
             Status
                     infant deaths
                                      Alcohol
                                               percentage expenditure
                                                                        Measles
      0 Developing
                                         0.01
                                                             71.279624
                                                                             1154
      1 Developing
                                 64
                                         0.01
                                                             73.523582
                                                                              492
      2 Developing
                                         0.01
                                 66
                                                             73.219243
                                                                              430
      3 Developing
                                 69
                                         0.01
                                                             78.184215
                                                                             2787
      4 Developing
                                 71
                                         0.01
                                                              7.097109
                                                                             3013
          BMI
                under-five deaths
                                      Total expenditure Diphtheria
                                                                        HIV/AIDS
      0
          19.1
                                                   8.16
                                 83
                                                                 65.0
                                                                              0.1
      1
          18.6
                                 86
                                                   8.18
                                                                 62.0
                                                                              0.1
      2
          18.1
                                 89
                                                   8.13
                                                                 64.0
                                                                              0.1
      3
          17.6
                                 93
                                                   8.52
                                                                 67.0
                                                                              0.1
      4
          17.2
                                 97
                                                   7.87
                                                                 68.0
                                                                              0.1
         Population
                       thinness
                                 1-19 years
                                               thinness 5-9 years
                                                                    Schooling
      0
         33736494.0
                                        17.2
                                                              17.3
                                                                         10.1
                                                                         10.0
      1
           327582.0
                                        17.5
                                                              17.5
      2
        31731688.0
                                        17.7
                                                              17.7
                                                                          9.9
      3
          3696958.0
                                        17.9
                                                              18.0
                                                                          9.8
      4
          2978599.0
                                        18.2
                                                              18.2
                                                                          9.5
[42]: from sklearn.tree import DecisionTreeRegressor
      from sklearn.preprocessing import LabelEncoder
      label_enc = LabelEncoder()
      X = df_status
      X['Status'] = label_enc.fit_transform(df_status['Status'])
      model = DecisionTreeRegressor()
      scores = cross_val_score(model, X, y_life, cv=5, scoring='r2')
      print("Scores de validación cruzada (R2):", scores)
      print("Score promedio (R2):", scores.mean())
```

Scores de validación cruzada (R2): [0.65795021 0.58395264 0.79681264 0.59678724 0.71007126]

Score promedio (R2): 0.669114798347221

df_status.head()

- Consideras que el modelo de regresión lineal es adecuado para los datos. ¿Por qué? Puede ser viable en el sentido de poder comprobar la relacion entre las variables de respuesta y predictoras pero otro modelo podria reflejar otro tipo de perspectiva al analisis de estos mismos datos.
- ¿Qué método de selección de características consideras que funciona bien con los datos? ¿Por qué? Definitivamente el metodo secuencial Filter-Wrapper funciona muy bien ya que es la que toma mas características para evaluar las relaciones de los datos con mejor lujo de detalle, es decir, toma mas características a comparacion de los otros metodos de seleccion.

- Del proceso de selección de características, ¿puedes identificar algunas que sean sobresalientes? ¿Qué información relevantes observas de dichas características? Las caracteristicas que mas llamaron la atención fueron aquellas que reflejan una gran correlación de los datos en conjunto con la esperanza de vida que reflejan la salud publica como por ejemplo infant deaths, percentage expenditure, under-five deaths.
- ¿El modelo de regresión no lineal funcionó mejor que el lineal? ¿Por qué? Ambos modelos funcionaron bien, el modelo lineal logra reflejar la relacion entre las diferentes caracteristicas mientras que el modelo no lineal logra reflejar la variabilidad entre las diferentes caracteristicas, ambos en comparacion con la variable de respuesta. Aun asi, para este caso el modelo no lineal funciona mejor para reflejar informacion mas relevante dentro del estudio.
- ¿Notas alguna mejora con el árbol de decisión al agregar la variable categórica "Status"? ¿Por qué? No diria que es una mejora, pero definitivamente se ve un resultado muy interesante al momento de cambiar la variable categorica ya que se puede ver como Status se ve directamente relacionada con el pais y la expectativa de vida alta.
- ¿Se puede concluir algo interesante sobre los resultados de modelar estos datos con regresión? Argumenta tu respuesta. La variable Status refleja como dependiendo de donve venga de pais de origen el dato y el estatus social y economico del mismo, la expectativa de vida aumenta considerablemente a comparacion de datos que provengan de paises donde el estatus social y economico no esten a la altura de paises mas desarrollados, reflejando una relacion mas grande con las demas categorias y bajando la expectativa de vida.