Actividad: Regresión Lineal

Andrés Alejandro Guzmán González - A01633819

Instrucciones:

Utiliza un modelo de regresión lineal múltiple para predecir el salario en dolares (salary_in_usd) de cada empleado. Las variables regresoras de tu modelo deben de ser las siguientes: nivel de experiencia (experience_level), tipo de empleo (employment_type), salario (salary) y radio remoto (remote_ratio).

Entrega un documento en formato PDF donde se observe la siguiente información.

1. Ecuación matemática que describe el modelo de regresión lineal a ejecutar. Se debe especificar el nombre de las variables.
2. Base de datos completa. No se observan valores faltantes. En caso de haberlos se realiza imputación simple.
3. Mostrar que las variables regresoras son independientes. En caso de no serlo realizar el procedimiento correspondiente.
4. Calculo de R^2, calculo de los coeficientes de regresión y p-valor; interpretación de resultados.
5. Comparación entre datos reales y predicción. Análisis de los resultados.
6. Análisis de los errores mediante diferentes medios (QQ-plot, histograma, test Kolmogorov etc.). Mostrar las gráficas correspondientes y el análisis de resultados

El trabajo se realizará de forma individual. La forma de entrega será mediante un documento PDF en canvas.

Column	Description
work_year	The year the salary was paid.
experience_level	The experience level in the job during the year with the following possible values: EN Entry-level / Junior MI Mid-level / Intermediate SE Senior-level / Expert EX Executive-level / Director
employment_type	The type of employement for the role: PT Part-time FT Full-time CT Contract FL Freelance
job_title	The role worked in during the year.
salary	The total gross salary amount paid.
salary_currency	The currency of the salary paid as an ISO 4217 currency code.
salary_in_usd	The salary in USD (FX rate divided by avg. USD rate for the respective year via fxdata.foorilla.com).
employee_residence	Employee's primary country of residence in during the work year as an ISO 3166 country code.
remote_ratio	The overall amount of work done remotely, possible values are as follows: 0 No remote work (less than 20%) 50 Partially remote 100 Fully remote (more than 80%)
company_location	The country of the employer's main office or contracting branch as an ISO 3166 country code.
company_size	The average number of people that worked for the company during the year: S less than 50 employees (small) M 50 to 250 employees (medium) L more than 250 employees (large)

```
#importación y llamado a librarías

import pandas as pd
import numpy as np
from sklearn.preprocessing import StandardScaler
from sklearn.model_selection import train_test_split
import statsmodels.formula.api as smf
import statsmodels.formula.api as smf
import matplotlib.pyplot as plt
import statsmodels.api as sm
import statsmodels.api as sm
from scipy import stats
```

```
# Lectura del Data Frame
df = pd.read_csv('/content/sample_data/ds_salaries.csv')
# Validación de la lectura del Data Frame
df.head()
```

	Unnamed: 0	work_year	experience_level	employment_type	job_title	salary	salary_currency	salary_i
0	0	2020	MI	FT	Data Scientist	70000	EUR	
1	1	2020	SE	FT	Machine Learning Scientist	260000	USD	2
2	2	2020	SE	FT	Big Data Engineer	85000	GBP	1
3	3	2020	MI	FT	Product Data Analyst	20000	USD	

```
# Consultamos el tamaño del Data Frame
df.shape
```

```
(607, 12)
```

```
# Validadmos que no haya valores faltantes o nulos
df.isnull().sum()
```

```
Unnamed: 0            0
work_year             0
experience_level      0
employment_type       0
job_title             0
salary                0
salary_currency       0
salary_in_usd         0
employee_residence    0
remote_ratio          0
company_location      0
company_size          0
dtype: int64
```

Quitamos la columna: 'Unnamed: 0'

```
# Quitamos del Data Frame las variables que no vamos a considerar en el modelo
df.drop('work_year', axis=1, inplace=True)
df.drop('job_title', axis=1, inplace=True)
df.drop('salary_currency', axis=1, inplace=True)
df.drop('employee_residence', axis=1, inplace=True)
df.drop('company_location', axis=1, inplace=True)
df.drop('company_size', axis=1, inplace=True)
df.head()
```

	Unnamed: 0	experience_level	employment_type	salary	salary_in_usd	remote_ratio
0	0	MI	FT	70000	79833	0
1	1	SE	FT	260000	260000	0
2	2	SE	FT	85000	109024	50
3	3	MI	FT	20000	20000	0
4	4	SE	FT	150000	150000	50

```
# Revisamos las categorías de la variable: 'experience_level'
df['experience_level'].unique()
```

```
array(['MI', 'SE', 'EN', 'EX'], dtype=object)
```

```
# Revisamos las categorías de la variable: 'experience_level'
df['employment_type'].unique()
```

```
array(['FT', 'CT', 'PT', 'FL'], dtype=object)
```

```
# Creamos las dummies de la variable categórica: 'experience_level'
dummies_exp_lev=pd.get_dummies(df['experience_level'], prefix='experience_level')
dummies_exp_lev
```

	experience_level_EN	experience_level_EX	experience_level_MI	experience_level_SE
0	0	0	1	0
1	0	0	0	1
2	0	0	0	1
3	0	0	1	0
4	0	0	0	1
...	...	...	...	...
602	0	0	0	1
603	0	0	0	1
604	0	0	0	1
605	0	0	0	1
606	0	0	1	0

607 rows × 4 columns

```
# Creamos las dummies de la variable categórica: 'employment_type'
dummies_emp_ty=pd.get_dummies(df['employment_type'], prefix='employment_type')
dummies_emp_ty
```

	employment_type_CT	employment_type_FL	employment_type_FT	employment_type_PT
0	0	0	1	0
1	0	0	1	0
2	0	0	1	0
3	0	0	1	0
4	0	0	1	0
...	...	...	...	...
602	0	0	1	0
603	0	0	1	0
604	0	0	1	0
605	0	0	1	0
606	0	0	1	0

607 rows × 4 columns

```
# Concatenamos las dummies al Data Frame
df = pd.concat([df,dummies_exp_lev, dummies_emp_ty],axis=1)
df
```

	Unnamed: 0	experience_level	employment_type	salary	salary_in_usd	remote_ratio	experience_level
0	0	MI	FT	70000	79833	0	

```
# Eliminamos del Data Frame las variables 'employment_type' - 'experience_level'
df.drop('employment_type', axis = 1, inplace = True)
df.drop('experience_level', axis = 1, inplace = True)
df
```

	Unnamed: 0	salary	salary_in_usd	remote_ratio	experience_level_EN	experience_level_EX	experienc
0	0	70000	79833	0	0	0	
1	1	260000	260000	0	0	0	
2	2	85000	109024	50	0	0	
3	3	20000	20000	0	0	0	
4	4	150000	150000	50	0	0	
...	...	...	...	...	...	...	
602	602	154000	154000	100	0	0	
603	603	126000	126000	100	0	0	
604	604	129000	129000	0	0	0	
605	605	150000	150000	100	0	0	
606	606	200000	200000	100	0	0	

607 rows × 12 columns

```
# Calculamos la correlación de las variables del modelo
correlacion = df.corr()
correlacion
```

	Unnamed: 0	salary	salary_in_usd	remote_ratio	experience_level_EN	experience_le
Unnamed: 0	1.000000	-0.096250	0.167025	0.095000	-0.199319	-0.
salary	-0.096250	1.000000	-0.083906	-0.014608	-0.015845	0.
salary_in_usd	0.167025	-0.083906	1.000000	0.132122	-0.294196	0.
remote_ratio	0.095000	-0.014608	0.132122	1.000000	-0.010490	0.
experience_level_EN	-0.199319	-0.015845	-0.294196	-0.010490	1.000000	-0.
experience_level_EX	-0.053909	0.014130	0.259866	0.041208	-0.087108	1.
experience_level_MI	-0.139869	0.074626	-0.252024	-0.127850	-0.302761	-0.
experience_level_SE	0.296579	-0.065995	0.343513	0.113071	-0.381033	-0.
employment_type_CT	-0.042856	-0.008268	0.092907	0.065149	0.066013	0.
employment_type_FL	-0.032304	-0.014568	-0.073863	-0.016865	-0.033537	-0.
employment_type_FT	0.094812	0.025685	0.091819	-0.023834	-0.167828	-0.
employment_type_PT	-0.078736	-0.020006	-0.144627	-0.002935	0.204028	-0.

```
# Validamos cuántas variables del modelo tienen alta correlación
alt_corr = np.where((correlacion > 0.95) & (correlacion < 1))
alt_corr
```

```
(array([], dtype=int64), array([], dtype=int64))
```

```
# Validamos cuántas variables del modelo tienen baja correlación
baja_corr = np.where((correlacion < -0.95) & (correlacion > -1))
baja_corr
```

```
(array([], dtype=int64), array([], dtype=int64))
```

```
# Estandarizamos los valores de las variables dummies para evitar la correlación entre estas
scaler = StandardScaler()
df_estandar = scaler.fit_transform(df)
df_estandar
```

```
array([[-1.72919969, -0.16460538, -0.45790445, ..., -0.0814463 ,
         0.17975796, -0.12942341],
       [-1.72349276, -0.0414754 ,  2.08328151, ..., -0.0814463 ,
         0.17975796, -0.12942341],
       [-1.71778583, -0.15488459, -0.04617667, ..., -0.0814463 ,
         0.17975796, -0.12942341],
       ...,
       [ 1.71778583, -0.12637028,  0.2355771 , ..., -0.0814463 ,
         0.17975796, -0.12942341],
       [ 1.72349276, -0.11276118,  0.53177399, ..., -0.0814463 ,
         0.17975796, -0.12942341],
       [ 1.72919969, -0.08035855,  1.23700468, ..., -0.0814463 ,
         0.17975796, -0.12942341]])
```

```
# Insertamos los valores de la estandarización en las columnas del Data Frame correspondientes
df_estandar = pd.DataFrame(df_estandar, columns=df.columns)
df_estandar
```

	Unnamed: 0	salary	salary_in_usd	remote_ratio	experience_level_EN	experience_level_EX	experie
0	-1.729200	-0.164605	-0.457904	-1.743615	-0.411773	-0.211543	
1	-1.723493	-0.041475	2.083282	-1.743615	-0.411773	-0.211543	
2	-1.717786	-0.154885	-0.046177	-0.514377	-0.411773	-0.211543	
3	-1.712079	-0.197008	-1.301826	-1.743615	-0.411773	-0.211543	
4	-1.706372	-0.112761	0.531774	-0.514377	-0.411773	-0.211543	
...	...	...	...	...	...	...	
602	1.706372	-0.110169	0.588192	0.714862	-0.411773	-0.211543	
603	1.712079	-0.128314	0.193263	0.714862	-0.411773	-0.211543	
604	1.717786	-0.126370	0.235577	-1.743615	-0.411773	-0.211543	
605	1.723493	-0.112761	0.531774	0.714862	-0.411773	-0.211543	
606	1.729200	-0.080359	1.237005	0.714862	-0.411773	-0.211543	

607 rows × 12 columns

```
# Procedemos a hacer la división del Data Frame en el conjunto de entrenamiento y prueba
entrenamiento, prueba = train_test_split(df_estandar, test_size=0.20, random_state=42)
entrenamiento
```

	Unnamed: 0	salary	salary_in_usd	remote_ratio	experience_level_EN	experience_level_EX	experie
9	-1.677837	-0.128962	0.179159	-0.514377	-0.411773	-0.211543	
227	-0.433727	-0.161365	-0.333488	-0.514377	-0.411773	-0.211543	
591	1.643596	-0.116096	0.459192	0.714862	-0.411773	-0.211543	
516	1.215576	-0.111141	0.567036	0.714862	-0.411773	-0.211543	
132	-0.975885	-0.185084	-1.042301	0.714862	-0.411773	-0.211543	
...	...	...	...	...	...	...	
71	-1.324008	-0.185991	-0.988746	-0.514377	-0.411773	-0.211543	
106	-1.124265	-0.057677	1.059879	0.714862	-0.411773	-0.211543	
270	-0.188329	-0.162985	-0.561334	0.714862	2.428524	-0.211543	
435	0.753315	-0.164605	-0.291738	0.714862	-0.411773	-0.211543	
102	-1.147093	6.918609	-1.072499	-0.514377	-0.411773	-0.211543	

485 rows × 12 columns

```
# Hacemos el modelo de regresión lineal
# Quitamos una de las variables dummies de cada conjunto
modelo = smf.ols(formula='salary_in_usd~salary+remote_ratio+experience_level_EN+experience_level_EX+experience_level_MI+employment_type_CT+em
modelo = modelo.fit()
print(modelo.summary())
```

```
                            OLS Regression Results
==============================================================================
Dep. Variable:          salary_in_usd   R-squared:                       0.264
Model:                            OLS   Adj. R-squared:                  0.252
Method:                 Least Squares   F-statistic:                     21.37
Date:                Thu, 17 Aug 2023   Prob (F-statistic):           8.41e-28
Time:                        23:24:41   Log-Likelihood:                -627.06
No. Observations:                 485   AIC:                             1272.
Df Residuals:                     476   BIC:                             1310.
Df Model:                           8
Covariance Type:            nonrobust
===========================================================================================
                              coef    std err          t      P>|t|      [0.025      0.975]
-------------------------------------------------------------------------------------------
Intercept                  0.0167      0.040      0.413      0.680      -0.063       0.096
salary                    -0.1455      0.065     -2.251      0.025      -0.272      -0.018
remote_ratio               0.0592      0.040      1.463      0.144      -0.020       0.139
experience_level_EN       -0.3717      0.044     -8.423      0.000      -0.458      -0.285
experience_level_EX        0.1902      0.040      4.698      0.000       0.111       0.270
experience_level_MI       -0.3225      0.044     -7.387      0.000      -0.408      -0.237
employment_type_CT         0.0980      0.050      1.974      0.049       0.000       0.196
employment_type_FL        -0.0042      0.058     -0.073      0.941      -0.117       0.109
employment_type_FT         0.0879      0.057      1.531      0.126      -0.025       0.201
==============================================================================
Omnibus:                      242.000   Durbin-Watson:                   1.979
Prob(Omnibus):                  0.000   Jarque-Bera (JB):             2005.484
Skew:                           2.000   Prob(JB):                         0.00
Kurtosis:                      12.123   Cond. No.                         2.46
==============================================================================

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
```

Análisis de resultados del Modelo

Una vez realizado el modelo de regresión lineal podemos identificar el valor de r^2 (Coeficinete de correlación) es 0.264. Este dato nos indica que el modelo se ajusta al conjunto de datos en un 26.4%. También se puede identificar que los valores de las variables: *remote_ratio*, *employment_type_FL* y *employment_type_FT* tienen un valor de p-valor de 0.144, 0.941 y 0.126 respectivamente. Al ser mayores a 0.05 aceptamos la hipótesis nula que iguala los coeficientes de dichas variables a 0, haciendo que no tengan impacto en el modelo. Con esto la función del modelo es:

y = -0.1455*x1 - 0.3717*x3 + 0.1902*x4 - 0.3225*x5 + 0.0980*x6

Donde :

- x1 es 'salary'
- x3 es 'experience_level_EN'
- x4 es 'experience_level_EX'
- x5 es 'experience_level_MI'
- x6 es 'employment_type_CT'

```
# Calculamos los valores de aproximación del modelo
y_aprox = -0.1455*prueba['salary'] + 0*prueba['remote_ratio'] - 0.3717*prueba['experience_level_EN'] + 0.1902*prueba['experience_level_EX'] -
y_aprox
```

```
563    0.358337
289    0.358832
76    -0.313609
78     0.754617
182   -0.306254
         ...
249    0.355532
365    0.358493
453   -0.315495
548    0.362222
235   -0.314552
Length: 122, dtype: float64
```

Análisis de errores

Una vez generados los valores de aproximación hacemos un compartivo con los valores reales y a través de su diferencia con la aproximación podemos hacer el análisis de errores.

```
tabla=pd.DataFrame({'Real': prueba['salary_in_usd'], 'Prediccion': y_aprox, 'Errores': prueba['salary_in_usd']-y_aprox})
tabla
```

	Real	Prediccion	Errores
563	0.394254	0.358337	0.035917
289	0.320205	0.358832	-0.038627
76	-0.173457	-0.313609	0.140152
78	2.224328	0.754617	1.469711
182	-1.217128	-0.306254	-0.910873
...	...	...	...
249	0.813866	0.355532	0.458334
365	0.370981	0.358493	0.012489
453	0.108636	-0.315495	0.424130
548	-0.186856	0.362222	-0.549078
235	-0.032411	-0.314552	0.282141

122 rows × 3 columns

Gráfico - valores reales vs valores predecidos

```
plt.scatter(prueba['salary_in_usd'], y_aprox, color='gray')
plt.plot(prueba['salary_in_usd'],prueba['salary_in_usd'], color='red')
plt.xlabel("Datos Reales")
plt.ylabel("Predicción")
```

```
Text(0, 0.5, 'Predicción')
```

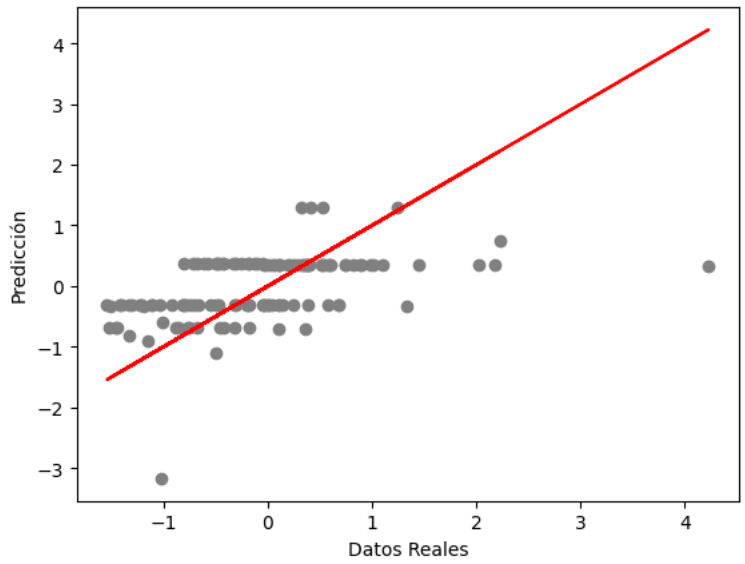

Al Analizar la dispersión de los datos se esperaría que estos se aproximen a la linea recta. Sin embargo, estos no siguen la línea de tendencia lo cual hace sentido por la baja correlación del modelo lo que demuestra que el modelo de regresión lineal multiple no es el mejor para predecir este conjunto de datos.

Gráfica de residuos

```
plt.scatter(range(l_residuos),tabla['Errores'], color='gray')
plt.axhline(y=0, linestyle='--', color='green')
```

```
plt.xlabel("No. de residuo")
plt.ylabel("Valor del residuo")
```

```
Text(0, 0.5, 'Valor del residuo')
```

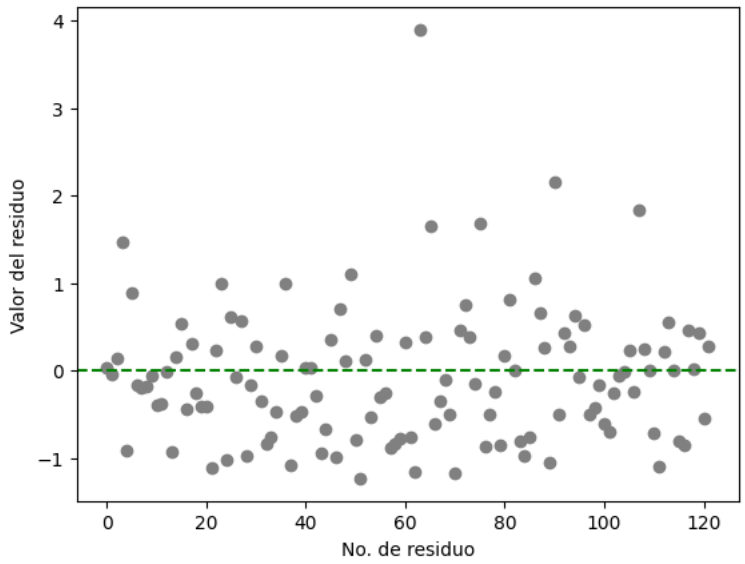

Nuevamente con la dispersión de errores se muestra que el Data Frame no se modela adecuadamente con un modelo de regresión lineal múltiple.

Histograma de residuos

```
plt.hist(x=tabla['Errores'], color='orange')
plt.title('Histograma residuos')
plt.xlabel("Residuos")
plt.ylabel("Frecuencia (Probabilidad)")
```

```
Text(0, 0.5, 'Frecuencia (Probabilidad)')
```

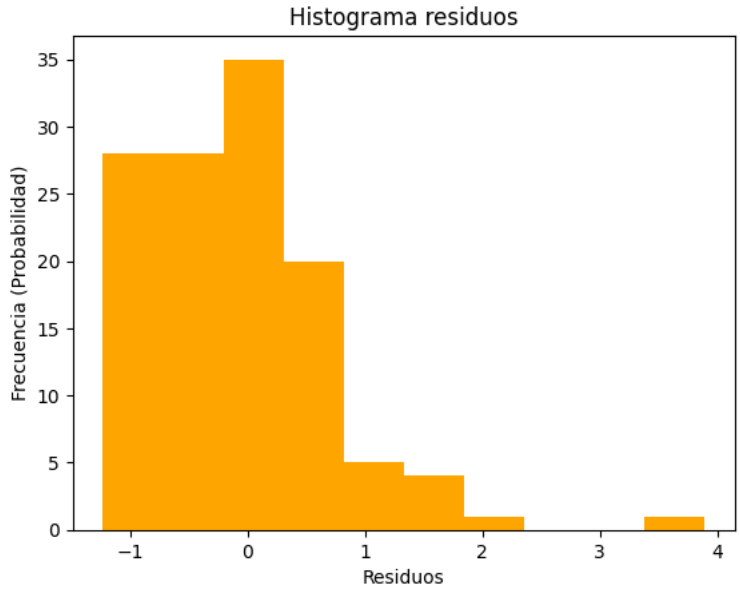

La forma del histograma nos muestra que los valores atípicos se cargan a la izquierda y afectan la distribución mostrando que los valores más pequeños tienen una mayor frecuencia.

QQ-Plot

```
QQ = sm.qqplot(tabla['Errores'], stats.norm, line='45')
```

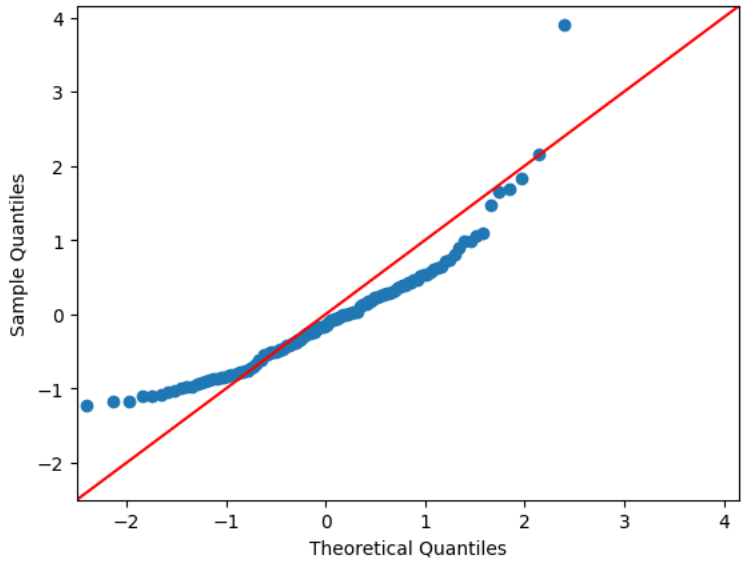

Para el QQ-Plot, se esperaría que los puntos se ajusten a la línea x=y. Lo que significaría que el valor de los errores es normal.

Modelo 2

Una opción que podría mejorar el modelo es quitar las variables en las que se aceptó la hipótesis nula; sin embargo al analizar el resultado vemos que el coeficiente de correlación se reduce a un 25.6%, por lo que se prefirió hacer el análisis en el modelo anterior.

```
modelo = smf.ols(formula='salary_in_usd~salary+experience_level_EN+experience_level_EX+experience_level_MI+employment_type_CT',data=entrenami
modelo = modelo.fit()
print(modelo.summary())
```

```
                            OLS Regression Results
==============================================================================
Dep. Variable:          salary_in_usd   R-squared:                       0.256
Model:                            OLS   Adj. R-squared:                  0.249
Method:                 Least Squares   F-statistic:                     33.04
Date:                Thu, 17 Aug 2023   Prob (F-statistic):           5.65e-29
Time:                        22:26:59   Log-Likelihood:                -629.63
No. Observations:                 485   AIC:                             1271.
Df Residuals:                     479   BIC:                             1296.
Df Model:                           5
Covariance Type:            nonrobust
===========================================================================================
                              coef    std err          t      P>|t|      [0.025      0.975]
-------------------------------------------------------------------------------------------
Intercept                   0.0179      0.041      0.443      0.658      -0.062       0.098
salary                     -0.1474      0.065     -2.282      0.023      -0.274      -0.020
experience_level_EN        -0.3904      0.043     -9.147      0.000      -0.474      -0.307
experience_level_EX         0.1920      0.041      4.734      0.000       0.112       0.272
experience_level_MI        -0.3292      0.044     -7.549      0.000      -0.415      -0.244
employment_type_CT          0.0583      0.041      1.428      0.154      -0.022       0.139
==============================================================================
Omnibus:                      239.133   Durbin-Watson:                   1.991
Prob(Omnibus):                  0.000   Jarque-Bera (JB):             1932.279
Skew:                           1.980   Prob(JB):                         0.00
Kurtosis:                      11.941   Cond. No.                         1.87
==============================================================================

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
```

✓ 0 s completado a las 17:24